Diplomamunka

Miskolci Egyetem

DIPLOMAMUNKA CÍME

Készítette:

Zsigó Bence

Mérnökinformatikus

Témavezető:

Dr. Tompa Tamás

egyetemi adjunktus

Miskolc, 2026

Miskolci Egyetem
Gépészmérnöki és Informatikai Kar
Alkalmazott Matematikai Intézeti Tanszék **Szám:**

Zsigó Bence (AGQU01) mérnökinformatikus jelölt részére.

A szakdolgozat tárgyköre:

A szakdolgozat címe:

A feladat részletezése:

Témavezető: Dr. Tompa Tamás, egyetemi adjunktus

A feladat kiadásának ideje:

. . . . . .
szakfelelős

Eredetiségi Nyilatkozat

Alulírott **Zsigó Bence**; Neptun-kód: `AGQUO1` a Miskolci Egyetem Gépészmérnöki és Informatikai Karának végzős Mérnökinformatikus szakos hallgatója ezennel büntetőjogi és fegyelmi felelősségem tudatában nyilatkozom és aláírásommal igazolom, hogy című diplomamunkám saját, önálló munkám; az abban hivatkozott szakirodalom felhasználása a forráskezelés szabályai szerint történt.

Tudomásul veszem, hogy szakdolgozat esetén plágiumnak számít:

- szószerinti idézet közlése idézőjel és hivatkozás megjelölése nélkül;
- tartalmi idézet hivatkozás megjelölése nélkül;
- más publikált gondolatainak saját gondolatként való feltüntetése.

Alulírott kijelentem, hogy a plágium fogalmát megismertem, és tudomásul veszem, hogy plágium esetén szakdolgozatom visszautasításra kerül.

Miskolc, 2024. május 10.

.....

Zsigó Bence

1.

szükséges (módosítás külön lapon)

A szakdolgozat feladat módosítása

nem szükséges

2023. február 12. .....

dátum témavezető(k)

2. A feladat kidolgozását ellenőriztem:

dátum:	a témavezető aláírása:
2023. október 09.	.....
2024. február 29.	.....
2024. április 01.	.....

3. A szakdolgozat beadható:

2024. május 10. .....

dátum témavezető(k)

4. A szakdolgozat szövegoldalt

1 db elektronikus adathordozót (CD)

tartalmaz.

2024. május 10. .....

dátum témavezető(k)

5.

bocsátható

A szakdolgozat bírálatra

nem bocsátható

A bíráló neve:

2024. május 10. .....

dátum szakfelelős

6. A szakdolgozat osztályzata

a témavezető javaslata: .....

a bíráló javaslata: .....

a szakdolgozat végleges eredménye: .....

Miskolc, ...

a Záróvizsga Bizottság Elnöke

Tartalomjegyzék

1. Bevezetés **1**

2. Gépi tanulás **2**
2.1. A gépi tanulás kialakulása és tudományos jelentősége 2
2.1.1. A gépi tanulás szerepe az intelligens rendszerekben 2
2.2. A gépi tanulás típusai 3
2.2.1. Felügyelt tanulás (Supervised Learning) 3
2.2.2. Felügyelet nélküli tanulás (Unsupervised Learning) 4
2.3. Kritikus kihívások és a kutatás irányai 5

3. Megerősítéses tanulás **7**
3.1. Az Ágens-Környezet Interakciós Ciklus 7
3.1.1. A Cél Függvény: A Diszkontált Jövőbeli Jutalmak 8
3.1.2. Értékfüggvények és Politika 8
3.1.3. Modellalapú vs. Modellmentes Megközelítések 9
3.2. Markov-döntési folyamat (MDP) 9
3.2.1. A Markov-tulajdonság: A "Memóriamentes" Jelen 9
3.2.2. Determinisztikus és Sztochasztikus Környezetek 10
3.3. Tanulási algoritmusok típusai 10
3.4. Q-learning 11
3.4.1. A Q-learning Frissítési Szabálya 11
3.5. SARSA 12
3.5.1. A SARSA Frissítési Szabálya és az On-Policy Különbség 12
3.5.2. A SARSA "Konzervatív" Természete és Gyakorlati Jelentősége . 13
3.6. RL kihívásai 13
3.7. Fuzzy rendszerek szerepe az RL-ben 14
3.8. Diszkrét módszerek korlátai folytonos környezetben 15

4. Fuzzy szabály-interpoláció alapú Q-learning **16**
4.1. Fuzzy halmazok és rendszerek 16
4.2. Fuzzy Szabályalapú Rendszerek Működése 17
4.2.1. A Fuzzy Következtetés Általános Folyamata 17
4.2.2. A Mamdani-típusú Következtetés 18
4.2.3. A Takagi–Sugeno-típusú Következtetés 18
4.2.4. A Klasszikus Módszerek Korlátai és Előnyei 19
4.3. Fuzzy szabály interpoláció 19
4.3.1. Az Interpolációs Módszerek Főbb Kategóriái 19
4.3.2. A FIVE Módszer: Alkalmazás-orientált Interpoláció 20
4.4. A Fuzzy Q-learning 22

4.5. Fuzzy szabály-interpoláció alapú rendszerek 23
4.5.1. FRIQ-learning 24

5. Többágensű Megerősítéses Tanulás (MARL) 28
5.1. Alapfogalmak és a nem-stacionaritás kihívása 28
5.2. Kooperatív, kompetitív és vegyes környezetek 28
5.3. Kommunikáció, koordináció és a CTDE paradigma 29
5.4. Érték- és politika-reprezentáció: VDN, QMIX és COMA 29
5.5. A MARL és az FRIQ-learning lehetséges kapcsolódási pontjai 30

6. Összefoglalás 31

Irodalomjegyzék 32

1. fejezet

Bevezetés

2. fejezet

Gépi tanulás

2.1. A gépi tanulás kialakulása és tudományos jelentősége

A gépi tanulás (Machine Learning, ML) fejlődése a mesterséges intelligencia kutatásának korai szakaszában gyökerezik, mára azonban a modern számítástudomány önálló és meghatározó diszciplínájává vált. Az ML alapvető paradigmaváltást hozott: a merev, programozott szabályok helyett az algoritmusok képessé váltak a tapasztalatokból történő önálló tanulásra.[1]

A terület egyik legfontosabb mérföldköve, amely a megerősítéses tanulás egyik korai előfutárának is tekinthető, Arthur Samuel 1952-es dámaprogramja volt. Ez a rendszer képes volt saját játszmáiból tanulva folyamatosan javítani teljesítményét, megvalósítva ezzel az egyik első, tapasztalati úton fejlődő alkalmazást [1, 2]. Bár a korai próbálkozások, mint Frank Rosenblatt 1957-es perceptronja [1, 3] , ígéretesnek tűntek a mintafelismerés terén, a technológiai korlátok és az elméleti kritikák az 1960-as évek végén a kutatások átmeneti megtorpanásához vezettek [2].

A terület fejlődésében az 1980-as és 1990-es évek hoztak jelentős elmozdulást a többrétegű hálózatok tanítását lehetővé tevő algoritmusok, valamint a statisztikai alapú modellek, például a döntési fák és támogatott vektorgépek elterjedésével [2]. A 2010-es évektől kezdve a mélytanulás (Deep Learning) és a konvolúciós hálózatok térnyerése, különösen az AlexNet sikere nyomán, új korszakot nyitott a komplex adatok feldolgozásában [1, 4].

2.1.1. A gépi tanulás szerepe az intelligens rendszerekben

A gépi tanulás központi szerepe abban rejlik, hogy hidat képez a szabályalapú megközelítések és a valós világ bizonytalanságai között. Míg az MI klasszikus ága az emberi logikát manuálisan leírt szabályokkal igyekezett utánozni, az ML algoritmusok az adatokban rejlő mintázatok önálló felfedezésére és az azokból történő általánosításra építenek [5].

Ez a váltás különösen az olyan komplex területeken vált elengedhetetlenné, mint a képfeldolgozás vagy a természetes nyelvfeldolgozás, ahol a hagyományos szabályrendszerek korlátai egyre nyilvánvalóbbá váltak [6]. A gépi tanulás ma már számos modern robotikai és autonóm rendszerben központi módszertani szerepet tölt be. A cél elmozdult a statikus utasításkövetéstől az aktív interakciókon alapuló, tapasztalati tudásszerzés felé [7, 8]. Ez az adatvezérelt megközelítés teremti meg az alapot az olyan hibrid

rendszerek számára is, mint a FRIQ-learning, amely a tapasztalati tanulást igyekszik ötvözni a szabályalapú következtetés rugalmasságával.

2.2. A gépi tanulás típusai

A gépi tanulás módszerei többféleképpen csoportosíthatók, de az egyik legáltalánosabb felosztás a tanulás módja szerint történik. Ez alapján megkülönböztetünk felügyelt tanulást (supervised learning), felügyelet nélküli tanulást (unsupervised learning), valamint a megerősítéses tanulást (reinforcement learning), amelyet a következő fejezet részletez [9].

2.2.1. Felügyelt tanulás (Supervised Learning)

A felügyelt tanulás a gépi tanulás egyik legelterjedtebb paradigmája, amely során az algoritmus egy címkézett adathalmazból tanul. Ez azt jelenti, hogy minden bemeneti adathoz (input) tartozik egy ismert és korrekt kimeneti érték (output, „címke”). A felügyelt tanulás alapvető célja egy olyan függvény (vagy modell) megtanulása, amely képes a bemeneti adatok és a hozzájuk tartozó kimeneti címkék közötti komplex kapcsolatot megragadni. Miután a modell sikeresen megtanulta ezt a leképezést a tréning adatokon, képes lesz új, eddig nem látott bemenetekhez is helyes kimenetet rendelni, ezáltal becsléseket vagy osztályozásokat végezni [5, 10].

A felügyelt tanulási feladatokat alapvetően két fő kategóriába sorolhatjuk a kimeneti változó jellege alapján:

- Osztályozás (Classification): Ebben az esetben a kimeneti változó diszkrét kategóriákat vagy osztályokat reprezentál. Az algoritmus célja, hogy egy adott bemeneti mintát a megfelelő osztályba soroljon. Példák közé tartozik az e-mail spamként vagy nem spamként való azonosítása (bináris osztályozás), vagy egy fényképfelvételen szereplő állatfaj (pl. kutya, macska, madár) felismerése (többosztályos osztályozás) [11].

- Regresszió (Regression): Amikor a kimeneti változó folytonos értéket vesz fel, regressziós problémáról beszélünk. A modell célja egy numerikus érték előrejelzése a bemeneti jellemzők alapján. Jellemző alkalmazási területei közé tartozik az időjárás-előrejelzés (pl. hőmérséklet), ingatlanárak becslése a ház mérete, elhelyezkedése és egyéb jellemzői alapján, vagy a részvényárfolyamok előrejelzése [10].

A felügyelt tanulásban számos különböző algoritmus létezik, amelyek mindegyike eltérő matematikai alapokra épül és más-más típusú problémákra optimalizált. Néhány közülük:

- Lineáris regresszió és Logisztikus regresszió: A lineáris regresszió folytonos kimeneti változók előrejelzésére szolgál, feltételezve a lineáris kapcsolatot a bemeneti és kimeneti változók között. A logisztikus regresszió, bár nevében regresszió, valójában osztályozási feladatokra használatos, különösen bináris osztályozás esetén, a kimenet valószínűségét adja meg egy adott osztályhoz való tartozásra [10].

- Döntési fák (Decision Trees) és Random Forests: A döntési fák olyan fa struktúrák, amelyekben minden belső csomópont egy attribútum tesztjét, minden ág egy teszt eredményét, és minden levélcsomópont egy osztálycímkét vagy numerikus értéket reprezentál. A Random Forest egy ensemble módszer, amely számos döntési fát épít és azok eredményeit átlagolja vagy szavazással kombinálja a jobb pontosság és a túltanulás csökkentése érdekében [12].

- Támogatott Vektorgépek (Support Vector Machines, SVM): Az SVM-ek célja egy olyan optimális hipersík megtalálása a nagy dimenziójú térben, amely a legjobban elválasztja az adatpontokat különböző osztályokba. Különösen hatékonyak magas dimenziójú terekben és viszonylag kis mintaszámú adathalmazokon is jól teljesítenek [13].

- Neurális hálózatok és mélytanulási architektúrák: A neurális hálózatok biológiai idegrendszerek ihlette, egymással összekapcsolt feldolgozó egységekből (neuronokból) álló hálózatok. A mélytanulás (deep learning) a neurális hálózatok azon ága, ahol számos (gyakran tíz- vagy száz) rejtett réteggel rendelkező hálózatokat használnak, lehetővé téve rendkívül komplex mintázatok és hierarchikus jellemzők automatikus kinyerését az adatokból. Ide tartoznak a konvolúciós neurális hálózatok (Convolutional Neural Networks, CNN) képfeldolgozásra, és a rekurrens neurális hálózatok (Recurrent Neural Networks, RNN) idősoros és szekvenciális adatokra, mint például a természetes nyelvfeldolgozás [6].

Alkalmazási területek és kihívások

A módszertan sikerrel alkalmazható az egészségügyi diagnosztikában, a pénzügyi csalásfelismerésben és a marketing-optimalizációban, amennyiben elegendő és jó minőségű címkézett adat áll rendelkezésre [14]. A gyakorlati alkalmazás során azonban szembe kell nézni az adatcímkézés magas költségeivel, a modell túlzott specializációjának (overfitting) veszélyével [10], valamint a tréning adatokban rejlő torzításokból (bias) eredő etikai kockázatokkal [15].

2.2.2. Felügyelet nélküli tanulás (Unsupervised Learning)

A felügyelet nélküli tanulás során az algoritmus címkézetlen adatokat kap, célja pedig az adatokban rejlő rejtett struktúrák, csoportosítások önálló felfedezése [9]. Ez a megközelítés kulcsfontosságú az adatok feltárásában és a dimenziócsökkentésben.

A legismertebb felügyelet nélküli algoritmusok típusai:

- Klaszterezés (Clustering): A klaszterezés célja, hogy az adatelemeket hasonlóságuk alapján csoportokba (klaszterekbe) rendezze, anélkül, hogy előzetesen ismernénk ezeknek a csoportoknak a definícióját vagy számát. Az azonos klaszterbe tartozó elemek egymáshoz hasonlítanak, míg a különböző klaszterekbe tartozó elemek lényegesen eltérnek egymástól [9].

  - K-means: Ez az egyik legnépszerűbb klaszterező algoritmus, amely a klaszterek középpontjait (centroidjait) iteratívan optimalizálja, minimalizálva az adatpontok és a hozzájuk tartozó centroidok közötti távolságot. Megköveteli a klaszterek számának (k) előzetes megadását [16].

  - Hierarchikus klaszterezés (Hierarchical Clustering): Ez a módszer hierarchikus fa struktúrát (dendrogramot) hoz létre, amely megmutatja az adatelemek közötti hasonlósági kapcsolatokat különböző szinteken. Lehet agglomeratív (lentről felfelé építkező) vagy divízív (fentről lefelé bontó) [16].
  - DBSCAN (Density-Based Spatial Clustering of Applications with Noise): A DBSCAN sűrűségi alapú klaszterezési algoritmus, amely képes tetszőleges alakú klasztereket találni, és képes a zajos adatpontok azonosítására is [17].

- Dimenziócsökkentés (Dimensionality Reduction): A dimenziócsökkentés célja az adatokban lévő változók (dimenziók) számának csökkentése, miközben a lényeges információk vagy az adatok mögötti struktúra nagyrészt megmarad. Ez nemcsak a vizualizációt segíti, hanem csökkentheti a számítási igényt és javíthatja a modellek teljesítményét is a „dimenziók átkának“(curse of dimensionality) elkerülésével [18].
  - Főkomponens-analízis (Principal Component Analysis, PCA): A PCA egy lineáris dimenziócsökkentési technika, amely az eredeti adatokból ortogonális transzformációval új, korrelálatlan változókat (főkomponenseket) hoz létre, amelyek a legnagyobb varianciát magyarázzák az adatokban [19].
  - t-SNE (t-Distributed Stochastic Neighbor Embedding): A t-SNE egy nemlineáris dimenziócsökkentési technika, amely különösen alkalmas magas dimenziójú adatok vizualizációjára alacsony dimenziójú térben, megőrizve az adatok közötti lokális hasonlóságokat [18].
  - Autoencoderek: A neurális hálózat alapú autoencoderek szintén dimenziócsökkentésre használhatók. Ezek a hálózatok megtanulnak egy sűrűsített, alacsony dimenziójú reprezentációt (kódot) a bemeneti adatokból, majd ebből a kódból próbálják rekonstruálni az eredeti bemenetet [20].

- Asszociációs szabályok bányászata (Association Rule Mining): Ez a módszer az adatokban lévő érdekes kapcsolatok és összefüggések (asszociációs szabályok) felfedezésére szolgál, különösen nagy tranzakciós adatbázisokban. Híres példa a „kosáranalízis“, ahol felfedezhetők a gyakran együtt vásárolt termékek (pl. „aki tejet vesz, nagy valószínűséggel kenyeret is vesz“) [21].

Alkalmazási területek és kihívások

A felügyelet nélküli tanulás meghatározó a vásárlói szegmentációban, az anomáliadetektálásban és a bioinformatikai génexpressziós vizsgálatokban. Előnye, hogy nem igényel költséges címkézést, ugyanakkor a kapott eredmények értelmezése gyakran szubjektív, és a teljesítmény mérése — egzakt címkék hiányában — komoly módszertani kihívást jelent.

2.3. Kritikus kihívások és a kutatás irányai

A lenyűgöző sikerek ellenére a technológia gyakorlati alkalmazása során számos korláttal szembesülünk, amelyek közvetlenül motiválják a hibrid megoldások, például a fuzzy-alapú megközelítések fejlesztését. A modellek értékét mindenekelőtt az általánosító képességük adja, azaz mennyire képesek stabilan működni ismeretlen adatokon.

A túltanulás (overfitting) és az alultanulás (underfitting) közötti egyensúly megtalálása továbbra is alapvető feladat a kutatók számára [10, 11]. Ez a probléma különösen kritikus az adatminőség kérdéskörében, ahol a zajos vagy inkonzisztens bemenetek radikálisan ronthatják a rendszerek teljesítményét [22]. Emellett a biztonság szempontjából az ellenséges támadásokkal (adversarial attacks) szembeni robusztusság növelése is kiemelt kutatási irányt jelent a modern környezetekben [23].

A technikai korlátok mellett a mélyneurális hálózatok „fekete doboz"jellege is komoly akadályt jelent a bizalmat igénylő területeken, mint az orvosi diagnosztika vagy az autonóm irányítás [24]. Ezen hiányosság hívta életre a magyarázható mesterséges intelligencia (Explainable AI, XAI) iránti igényt, amelyben a fuzzy rendszerek transzparens, szabályalapú logikája jelentős módszertani előnyt kínál [25, 24].

Ebből adódóan a jövőbeli kutatások egyik legfontosabb pillére a különböző tanulási stratégiák ötvözése, amely a korszerű RL rendszerek számára az alábbi meghatározó irányok mentén valósulhat meg:

- **Tudásátadás (Transfer Learning):** Lehetővé teszi a korábban megszerzett ismeretek adaptálását új feladatokra, jelentősen csökkentve a tanítóanyag iránti igényt [26, 27].
- **Sim2Real transzformáció:** A szimulált környezetben szerzett tudás valós fizikai térbe való átültetése [28], amely a robotikai alkalmazások és az FRIQ-learning szempontjából is kritikus jelentőségű.
- **Félfelügyelt és öntanuló rendszerek:** A címkézetlen adatok hatékony kihasználását célozzák, mérsékelve az emberi beavatkozás szükségességét az adatelőkészítés során [29, 30].

Ezek a törekvések együttesen egy olyan robusztusabb és átláthatóbb keretrendszer felé mutatnak, amely képes áthidalni a tisztán numerikus tanulás és a szakértői tudást integráló szabályalapú következtetés közötti szakadékot.

3. fejezet

Megerősítéses tanulás

A gépi tanulás paradigmái közül a megerősítéses tanulás (Reinforcement Learning, RL) modellezi leginkább az élőlények természetes, tapasztalati úton történő tanulási folyamatát. Nem előre címkézett adathalmazokból (mint a felügyelt tanulásnál), és nem is rejtett struktúrák passzív felfedezésével (mint a felügyelet nélküli tanulásnál) operál. Ehelyett egy aktív, döntéshozó **ágens** (agent) és egy dinamikus **környezet** (environment) közötti folyamatos interakcióra épül. Az ágens célja, hogy próba-szerencse alapon, a környezettől kapott visszajelzések, azaz **megerősítések** (jutalmak és büntetések) alapján megtanuljon egy optimális viselkedési stratégiát, vagyis **politikát** (policy) [31].

3.1. Az Ágens-Környezet Interakciós Ciklus

A megerősítéses tanulás lelke egy ciklikus folyamat, amely diszkrét időlépésekben ($t = 0, 1, 2, \dots$) zajlik. A ciklus minden egyes lépése a következőképpen írható le, ahogy azt a 3.1 ábra is szemlélteti:

1. **Megfigyelés:** A t időpillanatban az ágens megfigyeli a környezet aktuális állapotát, $s_t \in S$, ahol S az összes lehetséges állapot halmaza.

2. **Akció:** A megfigyelt állapot és a saját belső politikája (π) alapján az ágens kiválaszt egy akciót, $a_t \in A(s_t)$, ahol A az adott állapotban elérhető akciók halmaza.

3. **Visszacsatolás:** Az akció végrehajtását követően a környezet a $t+1$ időpillanatban egy új állapotba, s_{t+1}-be kerül, és egy skaláris értékű jutalmat, $r_{t+1} \in \mathbb{R}$ ad visszajelzésként az ágensnek.

Ez a $(s_t, a_t, r_{t+1}, s_{t+1})$ szekvencia ismétlődik folyamatosan. A jutalom az egyetlen visszajelzés, amit az ágens kap; ez jelzi, hogy az adott lépés mennyire volt "jó" a végső cél szempontjából, de nem ad direkt útmutatást arra, hogy melyik akció lett volna a helyes. Az ágens feladata, hogy ezen szűkös információ alapján, a múltbeli tapasztalatait összegezve rájöjjön, mely akciósorozatok vezetnek a legmagasabb összesített jutalomhoz [31, 32].

A tanulás gyakran **epizódokban** történik. Egy epizód egy kezdőállapottól egy terminális (vég)állapotig tart (pl. egy sakkjátszma a kezdőállástól a mattig). Az epizódok végén összegyűjtött tapasztalatok alapján az ágens finomítja a politikáját a következő epizódra.

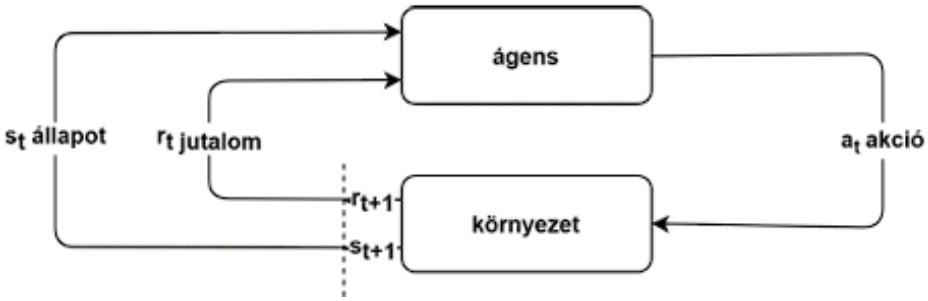

3.1. ábra. A megerősítéses tanulás alapciklusa: az ágens és a környezet interakciója [31, 32].

3.1.1. A Cél Függvény: A Diszkontált Jövőbeli Jutalmak

Az ágens végső célja nem egyetlen, azonnali jutalom maximalizálása, hanem a hosszú távon összegyűjtött, kumulatív jutalom maximalizálása. Ennek formalizálására a **diszkontált hozam** (discounted return, R_t) fogalmát használjuk:

$$G_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \cdots = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1} \tag{3.1}$$

ahol a $\gamma \in [0, 1]$ a **diszkontfaktor**. Ez a tényező azt szabályozza, hogy a jövőbeli jutalmak mekkora súllyal számítanak. Ha $\gamma = 0$, az ágens "rövidlátó", csak az azonnali jutalom érdekli. Ha γ közelít az 1-hez, az ágens "előrelátó", és a távoli jövőben bekövetkező jutalmakat is nagy súllyal veszi figyelembe [31].

3.1.2. Értékfüggvények és Politika

A tanulás során az ágens két kulcsfontosságú függvényt próbál megbecsülni, hogy optimális döntéseket hozhasson:

- **Politika (π):** Ez a függvény (vagy valószínűség-eloszlás) határozza meg az ágens viselkedését. Megadja, hogy egy adott s állapotban az ágens melyik a akciót választja: $\pi(a|s)$. A cél egy optimális politika, π_* megtalálása, amely minden állapotban a legmagasabb várható hozamot eredményezi.

- **Értékfüggvények (Value Functions):** Ezek a függvények azt becsülik meg, hogy egy adott helyzet "milyen jó".

- Az **állapot-érték függvény** ($v_\pi(s)$) megadja a várható hozamot, ha az ágens az s állapotból indul, és onnantól kezdve a π politikát követi.

- Az **akció-érték függvény** ($q_\pi(s, a)$), vagy más néven a **Q-függvény**, megadja a várható hozamot, ha az ágens az s állapotban az a akciót hajtja végre, és csak utána követi a π politikát. A Q-függvény a legtöbb modern RL algoritmus központi eleme, mert közvetlenül segít a legjobb akció kiválasztásában: abban az állapotban, ahol vagyunk, azt az akciót érdemes választani, amelyikhez a legmagasabb Q-érték tartozik.

enditemize A tanulás folyamata lényegében a Q-függvény és a politika iteratív, egymást kölcsönösen javító finomítása [31].

3.1.3. Modellalapú vs. Modellmentes Megközelítések

A **modellalapú** (model-based) módszereknél az ágens ismeri vagy megtanulja a környezet dinamikáját, így képes fejben tervezni. A **modellmentes** (model-free) módszerek ezzel szemben közvetlenül a tapasztalatokból, a kapott jutalmak és állapotváltozások alapján tanulnak. Utóbbiak rugalmasabbak, de több interakciót igényelhetnek a konvergenciához [31].

3.2. Markov-döntési folyamat (MDP)

Ahhoz, hogy a megerősítéses tanulás intuitív koncepcióját algoritmikusan kezelhetővé tegyük, szükségünk van egy precíz matematikai keretrendszerre, amely képes leírni az ágens és a környezet közötti szekvenciális döntéshozatali folyamatot. Ez a formális leírás a **Markov-döntési folyamat** (Markov Decision Process, MDP), amely a megerősítéses tanulási problémák túlnyomó többségének teoretikus alapját képezi [31]. Az MDP egy olyan absztrakt modell, amely leírja, hogyan hoz egy döntéshozó (az ágens) akciókon keresztül döntéseket egy dinamikusan változó környezetben, a hosszú távú kumulatív jutalom maximalizálásának céljával.

Egy diszkrét idejű MDP-t formálisan egy öt komponensből álló tuplével, (S, A, P, R, γ), definiálhatunk, amely az egész folyamat "anatómiáját" leírja [31, 33]:

- **S (Állapottér):** Az összes lehetséges állapot halmaza, amelyben a környezet tartózkodhat. Ez lehet diszkrét (pl. egy sakktábla állásai) vagy folytonos (pl. egy robotkar csuklóinak szögei).
- **A (Akciótér):** Az összes lehetséges akció halmaza, amelyet az ágens végrehajthat.
- **P (Állapotátmeneti modell):** A környezet dinamikáját leíró függvény, $P(s'|s, a)$, amely megadja annak a valószínűségét, hogy az s állapotban az a akciót végrehajtva a környezet a következő lépésben az s' állapotba kerül. Lényegében ez a környezet "fizikája" vagy "játékszabálya".
- **R (Jutalomfüggvény):** A feladat célját definiáló függvény, $R(s, a, s')$, amely megadja a várható azonnali jutalmat, amelyet az ágens az s állapotból az a akcióval az s' állapotba való átmenetért kap.
- γ **(Diszkontfaktor):** Egy 0 és 1 közötti érték, amely az ágens "türelmét" vagy "előrelátását" szabályozza, meghatározva a jövőbeli jutalmak jelenértékét.

3.2.1. A Markov-tulajdonság: A "Memóriamentes" Jelen

Az MDP keretrendszer központi feltételezése a **Markov-tulajdonság**. Ez a tulajdonság kimondja, hogy a jövőbeli állapotok valószínűségi eloszlása kizárólag a jelenlegi állapottól és a választott akciótól függ; a múltbéli állapotok és akciók teljes története irreleváns [34]. Ezt egy sakkjátszma analógiájával lehet a legjobban megérteni: a következő lépés optimális megtervezéséhez elegendő a tábla jelenlegi állását ismernünk. Teljesen mindegy, hogy a figurák milyen lépéssorozat révén jutottak a jelenlegi pozíciójukba; minden, a jövőre vonatkozó releváns információ benne van a jelenlegi állapotban.

Matematikailag ez a következőképpen fejezhető ki:

$$\mathbb{P}[S_{t+1} = s' \mid S_t = s, A_t = a] = \mathbb{P}[S_{t+1} = s' \mid S_t, A_t, S_{t-1}, A_{t-1}, \ldots, S_0, A_0] \tag{3.2}$$

Ez a "memóriamentes" feltételezés drámaian leegyszerűsíti a problémát. Enélkül az ágensnek a teljes, egyre növekvő hosszúságú múltbeli történetet figyelembe kellene vennie a döntéseinél, ami a feladatot számításilag kezelhetetlenné tenné.

3.2.2. Determinisztikus és Sztochasztikus Környezetek

A környezet dinamikája, vagyis az állapotátmeneti modell (P) és a jutalomfüggvény (R) alapján megkülönböztetünk két fő MDP típust [35]:

- **Determinisztikus MDP:** Ebben az esetben a világ tökéletesen kiszámítható. Egy adott (s, a) állapot-akció párhoz mindig pontosan ugyanaz az s' következő állapot és r jutalom tartozik. Az átmeneti valószínűség, $P(s'|s, a)$, mindig 0 vagy 1. Ez egy idealizált eset, amely leginkább szimulált környezetekben vagy egyszerűbb problémáknál fordul elő.

- **Sztochasztikus MDP:** A valós világ legtöbb problémája bizonytalanságot tartalmaz. Egy robot csúszós felületen mozog, egy kártyajátékban a következő lap véletlenszerű. A sztochasztikus MDP-k ezt a bizonytalanságot modellezik. Egy adott (s, a) párból többféle s' állapot is bekövetkezhet, mindegyik egy bizonyos valószínűséggel. Az ágensnek itt nemcsak a jutalmak várható értékét kell maximalizálnia, hanem a stratégiájának robusztusnak is kell lennie a környezet véletlenszerűségével szemben, ami jelentősen megnehezíti az optimális politika megtalálását. A jutalomfüggvény, $R(s, a, s')$, itt is a várható jutalmat adja meg az adott átmenetre [36].

3.3. Tanulási algoritmusok típusai

Az MDP megoldására három alapvető paradigma létezik, amelyek a környezetről alkotott tudás felhasználásában térnek el.

A dinamikus programozás (DP) módszerei a Bellman-egyenleteket használják iteratív frissítési szabályokként, feltételezve a környezet teljes matematikai modelljének ismeretét [31]. Két fő megközelítése a politika-iteráció, amely a politika kiértékelésének és javításának váltakozó folyamata, valamint az érték-iteráció, amely közvetlenül az optimális értékfüggvényt keresi a Bellman-optimalitási egyenlet ismételt alkalmazásával. Bár ezek az eljárások elméletileg garantálják az optimális megoldást, a tökéletes modelligény és a jelentős számítási komplexitás miatt a gyakorlatban, komplex környezetekben ritkán alkalmazhatók.

A modellmentes Monte Carlo (MC) módszerek ezzel szemben nem igényelnek előzetes tudást a környezet dinamikájáról, hanem közvetlenül a lezajlott epizódok tapasztalataiból tanulnak [31]. Az értékbecslés ($V(s)$) frissítése kizárólag az epizód végén, a terminális állapot elérése után történik a ténylegesen megszerzett hozam (G_t) alapján az alábbi szabály szerint:

$$V(s) \leftarrow V(s) + \alpha(G_t - V(s)) \tag{3.3}$$

Ezen megközelítés előnye az egyszerűségben és a modellmentességben rejlik, azonban jelentős hátránya a magas variancia és a lassú tanulási ciklus, mivel minden módosításhoz meg kell várni az aktuális epizód befejezését.

A temporális differencia (TD) tanulás elegánsan ötvözi a DP és az MC előnyeit: modellmentesen tanul a tapasztalatokból, ugyanakkor a DP-hez hasonlóan minden egyes időlépés után frissíti becsléseit (*bootstrapping*) [31]. A TD(0) algoritmus frissítési szabálya a következő:

$$V(s_t) \leftarrow V(s_t) + \alpha \left[r_{t+1} + \gamma V(s_{t+1}) - V(s_t) \right] \tag{3.4}$$

A frissítés alapja a szögletes zárójelben szereplő **TD-hiba**, amely az azonnali jutalom és a következő állapot becsült értékének diszkontált összegét (TD-cél) veti össze a jelenlegi becsléssel. Ez a módszer lehetővé teszi a folyamatos, lépésenkénti tanulást, és drasztikusan felgyorsítja a konvergenciát a tisztán epizodikus módszerekhez képest.

3.4. Q-learning

A temporális differencia (TD) alapú tanulási módszerek közül a Q-learning az egyik legkorábbi, legbefolyásosabb és legszélesebb körben ismert algoritmus. Christopher Watkins 1989-es munkájában bemutatott eljárás [37] egy olyan **modellmentes** (model-free) technika, amely lehetővé teszi az ágens számára, hogy a környezet belső dinamikájának ismerete nélkül, pusztán a tapasztalati úton szerzett interakciókból tanuljon.

A Q-learning legfontosabb megkülönböztető jegye, hogy **off-policy** (politikafüggetlen) módszer. Ez azt jelenti, hogy képes az optimális akció-érték függvényt (q_*) megtanulni, miközben egy teljesen más, feltáró jellegű (exploratív) politikát követ a tapasztalatszerzés során. Más szóval, az ágens "félrenézhet" és kipróbálhat véletlenszerű vagy szuboptimálisnak tűnő akciókat is, de a tanult tudása mindig a feltételezett legjobb, "mohó" stratégia felé fog konvergálni. Ez a kettősség rendkívül hatékonnyá teszi a felfedezés-kiaknázás dilemma kezelésében [31].

3.4.1. A Q-learning Frissítési Szabálya

Az algoritmus lelke egy egyszerű, iteratív frissítési szabály, amely minden egyes tapasztalat után módosítja a Q-függvény becsült értékét $(s_t, a_t, r_{t+1}, s_{t+1})$. A frissítési egyenlet a Bellman-egyenlet egyfajta sztochasztikus approximációja:

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left[\underbrace{r_{t+1} + \gamma \max_{a'} Q(s_{t+1}, a')}_{\text{TD cél}} - Q(s_t, a_t) \right] \tag{3.5}$$

Az egyenlet komponenseinek értelmezése kulcsfontosságú a működés megértéséhez:

- $Q(s_t, a_t)$: Ez a jelenlegi, "régi" becslésünk az (s_t, a_t) pár értékére.
- α: A **tanulási ráta** (learning rate), egy 0 és 1 közötti paraméter, amely azt szabályozza, hogy az új tapasztalat milyen mértékben írja felül a régit. Egy alacsony α érték lassú, megfontolt tanulást, míg egy magas érték gyors, de potenciálisan instabil változásokat eredményez.

- $r_{t+1} + \gamma \max_{a'} Q(s_{t+1}, a')$: Ez a kifejezés a **TD-cél** (TD Target), amely egy új, a tapasztalat alapján finomított becslést ad a $Q(s_t, a_t)$ értékére. Két részből áll: a *valódi*, azonnal megkapott jutalomból (r_{t+1}) és a jövőbeli jutalmak diszkontált, *becsült* maximumából ($\gamma \max_{a'} Q(s_{t+1}, a')$).

- $\max_{a'} Q(s_{t+1}, a')$: Ez a tag teszi az algoritmust off-policy jellegűvé. A frissítés során az algoritmus "optimistán" feltételezi, hogy a következő, s_{t+1} állapotból kiindulva az ágens mindig a lehető legjobb akciót fogja választani – azt, amelyikhez a legmagasabb Q-érték tartozik. Ezt az értéket használja a frissítéshez, függetlenül attól, hogy a viselkedési politika (pl. egy ϵ-mohó stratégia) a következő lépésben ténylegesen melyik akciót fogja választani.

A szögletes zárójelben lévő teljes kifejezés a TD-hiba, amely a "régi" és az "új" becslés közötti különbséget méri. A tanulás során az algoritmus iteratívan csökkenti ezt a hibát, így a Q-értékek fokozatosan konvergálnak a valódi optimális értékek felé.

3.5. SARSA

A Q-learning mellett a temporális differencia (TD) tanulás másik alapvető algoritmusa a SARSA. A neve nem egy szerzőre utal, hanem egy mozaikszó, amely az algoritmus frissítési lépéséhez szükséges adatok sorrendjét írja le: **S**tate (állapot), **A**ction (akció), **R**eward (jutalom), **S**tate (következő állapot), **A**ction (következő akció) [38]. Ez a név egyben az algoritmus működésének kulcsát is magában hordozza.

A SARSA, a Q-learninghez hasonlóan, egy **modellmentes** (model-free) eljárás, amely a Q-függvény (akció-érték függvény) becslésével operál. A legfontosabb megkülönböztető jegye azonban, hogy a Q-learninggel ellentétben egy **on-policy** (politikakövető) algoritmus. Ez azt jelenti, hogy a SARSA mindig annak a politikának az értékét tanulja meg, amelyet éppen követ. Nem tesz optimista feltételezéseket a jövőbeli legjobb lépésekről, hanem a valós, tényleges viselkedéséből von le következtetéseket.

3.5.1. A SARSA Frissítési Szabálya és az On-Policy Különbség

A SARSA frissítési egyenlete első pillantásra rendkívül hasonló a Q-learningéhez, de egyetlen, kulcsfontosságú ponton eltér:

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left[r_{t+1} + \gamma Q(s_{t+1}, a_{t+1}) - Q(s_t, a_t) \right] \tag{3.6}$$

Az egyenlet felépítése (a régi érték frissítése a TD-hiba alapján) megegyezik a TD-tanulás általános logikájával. A lényegi különbség a TD-cél (a szögletes zárójelben lévő első két tag) meghatározásában rejlik:

- A **Q-learning** frissítése a $\max_{a'} Q(s_{t+1}, a')$ tagot használja. Ez egy elméleti maximum: "Mi lenne a legjobb lehetséges érték, amit a következő állapotból elérhetnék, ha ott a legmohóbb akciót választanám?"

- A **SARSA** frissítése ezzel szemben a $Q(s_{t+1}, a_{t+1})$ tagot használja. Ez a valóságot tükrözi: "Miután az s_t állapotból az a_t akcióval eljutottam az s_{t+1} állapotba, a jelenlegi politikám szerint melyik lesz a *tényleges következő akció*, az a_{t+1}? Ennek a valós következő lépésnek mi a becsült értéke?"

Ez a különbségtétel jelenti az on-policy tanulás lényegét. A SARSA a teljes $(s_t, a_t, r_{t+1}, s_{t+1}, a_{t+1})$ tapasztalati ötöst felhasználja a tanuláshoz. Mivel a tanult értékek a ténylegesen követett, felfedezést is tartalmazó (pl. ϵ-mohó) politikát tükrözik, a kapott Q-függvény a valós viselkedés értékét fogja becsülni, nem pedig egy ideális, de soha nem tökéletesen követett optimális politikáét [31].

3.5.2. A SARSA "Konzervatív" Természete és Gyakorlati Jelentősége

Az on-policy jelleg egy sokkal "konzervatívabb" vagy "realistább" tanulási viselkedést eredményez a Q-learning "optimista" megközelítésével szemben. Ennek a legismertebb szemléltetése a "szikla peremén sétálás" (cliff walking) probléma. Képzeljünk el egy ágenst, amelynek egy rácsvilágban kell eljutnia a startból a célba. A legrövidebb út egy szakadék pereme mellett vezet. A szakadékba lépés nagy negatív jutalommal jár.

- A **Q-learning** az optimális útvonalat tanulja meg, ami a szakadék peremén halad. Bár ez elméletileg a legjobb, a felfedezést végző ϵ-mohó politika miatt az ágens időnként véletlenül "le fog lépni" a peremről a szakadékba. A Q-learning ezt a kockázatot nem árazza be a Q-értékeibe.

- A **SARSA** viszont a saját, ϵ-mohó politikájának értékét tanulja. Észre fogja venni, hogy a szakadék melletti állapotok veszélyesek, mert a véletlenszerű lépések miatt nagy eséllyel negatív jutalomhoz vezetnek. Emiatt a SARSA egy biztonságosabb, a szakadéktól távolabb vezető, de kissé hosszabb útvonalat fog optimálisnak találni.

Ez a tulajdonsága teszi a SARSA-t különösen értékessé a **biztonságkritikus alkalmazásokban**, például a robotikában vagy autonóm járművek irányításánál. Ilyen területeken gyakran fontosabb egy megbízható és biztonságos, szuboptimális megoldás, mint egy elméletileg tökéletes, de a valóságban kockázatos stratégia követése [31].

Mind a Q-learning, mind a SARSA a modern megerősítéses tanulás alapköveinek számítanak. Bár alapformájukban diszkrét állapot- és akcióterekre korlátozódnak, a függvényapproximációs technikákkal (mint a neurális hálózatok vagy a fuzzy rendszerek) való kombinálásuk lehetővé teszi alkalmazásukat komplex, folytonos problémák megoldására is.

3.6. RL kihívásai

Az egyik legalapvetőbb kihívás az **exploit (kiaknázás) vs. explore (felfedezés)** dilemma [31]. Az ágensnek döntenie kell, hogy a már megszerzett tudását használja-e fel (exploit) a maximális jutalom eléréséhez, vagy új, még nem kipróbált akciókat fedez fel (explore) abban a reményben, hogy jobb jutalmakat talál. Ha túl sokat „exploitál“, akkor lokális optimumokba ragadhat, és nem találja meg a globálisan optimális politikát. Ha túl sokat „explore-ol“, akkor nem hasznosítja hatékonyan a megszerzett tudását, és a tanulási folyamat lassú, ineffektív lesz.

Ennek a dilemmának a kezelésére számos stratégia létezik:

- **ϵ-greedy:** Az ágens az idő ϵ hányadában véletlenszerűen választ akciót (felfedezés), és $1 - \epsilon$ hányadában a jelenlegi legjobb akciót választja (kiaknázás) [31]. Az

ϵ értéke gyakran az idő múlásával csökken, hogy a tanulási folyamat elején több felfedezést, később pedig több kiaknázást tegyen lehetővé.

- **Upper Confidence Bound (UCB):** Ez a módszer olyan akciókat részesít előnyben, amelyeknek magas a becsült értéke, vagy kevésbé lettek kipróbálva [39].
- **Thompson Sampling:** Valószínűségi megközelítést alkalmaz, ahol az akciók valószínűsége a korábbi megfigyelések alapján származtatott eloszlásokból húzott minták szerint történik [40].

Folytonos állapottér, ritka jutalmazás

- **Folytonos állapottér és akciótér:** Sok valós világ probléma folytonos állapot- és akcióteret tartalmaz, mint például egy robot karjának mozgása. A diszkrét táblázatokon alapuló algoritmusok (pl. Q-tábla) nem alkalmazhatók közvetlenül ezekben az esetekben, mivel az állapotok száma végtelen. Ezt a problémát gyakran **funkcióapproximációval** (function approximation) oldják meg, ahol neurális hálózatokat vagy más regressziós modelleket használnak az értékfüggvények vagy a politika paramétereinek becslésére [31]. Ez azonban bevezeti a generalizáció és a konvergencia stabilitásának problémáját.
- **Ritka jutalmazás (Sparse Rewards):** Bizonyos feladatokban az ágens csak nagyon ritkán kap pozitív jutalmat (pl. egy labirintus kijáratának megtalálása). Ez megnehezíti a tanulást, mivel az ágens nem kap elegendő visszajelzést ahhoz, hogy hatékonyan frissítse a politikáját. Ezt a problémát különböző technikákkal próbálják kezelni, mint például:
  - **Jutalom formálása (Reward Shaping):** Kiegészítő jutalmak bevezetése, amelyek segítik az ágenset a cél felé terelni, anélkül, hogy megváltoztatnák az optimális politikát [41].
  - **Prioritized Experience Replay:** Az ágens a fontosabb tapasztalatokat gyakrabban tanulmányozza újra [42].
  - **Curriculum Learning:** A feladat fokozatos nehezítése, hogy az ágens először egyszerűbb részeket sajátítson el [43].

3.7. Fuzzy rendszerek szerepe az RL-ben

A fuzzy logika [25] alternatívát kínál a folytonos terek kezelésére és a **Fuzzy Reinforcement Learning (FRL)** keretében az alábbi előnyöket nyújtja [44, 45]:

- **Rugalmas diszkretizáció:** Az állapotok tagsági fokokkal írhatók le, mérsékelve a "dimenziók átkát".
- **Magyarázhatóság:** A döntési politika érthető fuzzy szabályok formájában reprezentálható.
- **Robusztusság:** Jobban kezeli a bemeneti zajt és a bizonytalanságot.

3.8. Diszkrét módszerek korlátai folytonos környezetben

A hagyományos Reinforcement Learning algoritmusok, mint például a Q-learning, diszkrét állapot- és akcióterekre lettek tervezve. Ezek az algoritmusok Q-táblázatokat építenek, ahol minden állapot-akció párhoz egy Q-érték tartozik. Azonban a valós világban a legtöbb környezet **folytonos** állapotokkal és/vagy akciókkal rendelkezik (pl. robot mozgása, hőmérséklet, sebesség).

A folytonos terek kezelése számos nehézséget okoz a diszkrét tanulási módszerek számára:

- **Végtelen állapottér:** A folytonos állapotok száma végtelen, ami lehetetlenné teszi a Q-táblázat explicit felépítését és tárolását.
- **Generalizáció hiánya:** Ha diszkretizálnánk a folytonos teret, azaz véges számú intervallumra osztanánk, az állapottér exponenciálisan növekedne a dimenziók számával (dimenzió átka). Ráadásul az ágensnek minden egyes diszkretizált „cellában“külön kellene tanulnia, és nem tudna generalizálni a szomszédos cellákra.
- **Pontosság elvesztése:** A diszkretizáció során információveszteség lép fel, ami ronthatja a megoldás pontosságát.
- **A lokális változások érzékenysége:** Egy kis változás a folytonos állapotban teljesen más diszkrét állapotot eredményezhet, ami instabilitást okozhat a tanulásban.

Ezek a problémák rávilágítanak arra, hogy a diszkrét RL algoritmusok nem alkalmasak önmagukban a folytonos környezetek kezelésére.

4. fejezet

Fuzzy szabály-interpoláció alapú Q-learning

4.1. Fuzzy halmazok és rendszerek

A digitális rendszerek és a klasszikus matematika alapját a bináris logika képezi, ahol egy állítás egyértelműen igaz vagy hamis, egy elem pedig vagy tagja egy halmaznak, vagy sem. Ez a kétértékű, *éles* (crisp) logika tökéletesen alkalmas precíz számítási feladatok elvégzésére, azonban nehézségekbe ütközik, amikor az emberi gondolkodás és a valós világ pontatlan, szubjektív fogalmait kell modellezni. Olyan minőségi jellemzők, mint a *kellemes hőmérséklet* vagy egy *jármű sebessége*, nem rendelkeznek éles határokkal; egy átmeneti zónában léteznek, ahol a kategóriák közötti váltás fokozatos.

Ezt a kihívást ismerte fel Lotfi A. Zadeh, amikor 1965-ben publikálta a fuzzy, azaz elmosódott halmazokról szóló alapvető cikkét [25]. Célja egy olyan matematikai keretrendszer létrehozása volt, amely képes kezelni a bizonytalanságot és a pontatlanságot, áthidalva a szakadékot a gépi precizitás és az emberi nyelv árnyaltsága között. A fuzzy logika nem a hagyományos logika leváltását, hanem annak kiterjesztését célozza, lehetővé téve a "részleges igazságok" kezelését.

A fuzzy elmélet sarokköve a **tagsági függvény** (*membership function*), jelölése $\mu_A(x)$. Míg a klasszikus halmazoknál a tagság értéke $\{0, 1\}$, addig a fuzzy halmazoknál a tagsági függvény egy $[0, 1]$ zárt intervallumbeli valós értéket rendel minden elemhez [46]. Az érték a halmazhoz való tartozás mértékét, fokát fejezi ki: a 0 a teljes kizárást, az 1 a teljes, egyértelmű tagságot jelenti. Egy fuzzy halmazt teljes mértékben a tagsági függvénye definiál, amelynek alakja a gyakorlatban leggyakrabban egyszerűen kezelhető forma, mint a háromszög, trapéz vagy Gauss-görbe [47].

A fuzzy logika ereje a **nyelvi változók** (*linguistic variables*) bevezetésében rejlik, amelyek lehetővé teszik a numerikus skálák és a természetes nyelv összekapcsolását. Egy nyelvi változó (pl. *JárműSebesség*) olyan **nyelvi értékeket** (pl. *lassú*, *mérsékelt*, *gyors*) vehet fel, ahol minden egyes nyelvi érték egy fuzzy halmaznak felel meg [46, 47].

Vegyünk egy konkrét példát. Tegyük fel, hogy egy jármű sebességét a $[0, 150]$ km/h univerzumon vizsgáljuk.

- A *lassú* sebességet reprezentálhatja egy trapéz tagsági függvény, amely 30 km/h alatt 1, majd 50 km/h-ig lineárisan csökken 0-ra.

- A *mérsékelt* sebesség lehet egy háromszög függvény, amelynek csúcsa (ahol a tagság értéke 1) 80 km/h-nál van, és a függvény 50 km/h-nál és 110 km/h-nál éri

el a 0 értéket.

- A *gyors* sebességet ismét egy trapéz írhatja le, amely 110 km/h-tól lineárisan növekszik 1-ig (ezt 130 km/h-nál éri el), és efelett a tagsági érték végig 1 marad.

Ezzel a modellel egy 60 km/h-s sebesség egyszerre lehet valamennyire *lassú* és valamennyire *mérsékelt* is, ami sokkal jobban leírja a valóságot, mint egy merev kategória.

A fuzzy halmazokon a logikai műveletek is értelmezhetők. A logikai ÉS műveletnek a metszet (t-norma), leggyakrabban a *minimum* operátor felel meg, míg a VAGY műveletnek az unió (s-norma), jellemzően a *maximum* operátor [25]. A gyakorlatban más operátorcsaládok, mint a Yager- vagy Dombi-féle normák is használatosak, amelyek eltérő logikai viselkedést modelleznek [48, 49].

4.2. Fuzzy Szabályalapú Rendszerek Működése

A fuzzy logika igazi ereje a gyakorlati alkalmazásokban, a fuzzy következtető rendszerekben (Fuzzy Inference Systems – FIS) mutatkozik meg. Ezek a rendszerek a fuzzy halmazelméletet és a nyelvi változókat egy tudásalapú keretrendszerbe integrálják, amelynek magját az emberi szakértői gondolkodást utánzó, intuitív **HA-AKKOR** szabályok alkotják [50, 51]. Egy ilyen szabályrendszer teszi lehetővé, hogy a rendszer bemeneti adatok alapján komplex döntéseket hozzon.

Egy szabály alapvető szerkezete két részből áll: az *antecedensből* (a HA-rész, amely a feltételt tartalmazza) és a *konzekvensből* (az AKKOR-rész, amely a következményt írja le). Például egy egyszerű klímavezérlés szabálya lehet: *HA a "szoba hőmérséklete" a "meleg" fuzzy halmazba tartozik, AKKOR a "hűtés intenzitása" legyen "erős".*

4.2.1. A Fuzzy Következtetés Általános Folyamata

Függetlenül a konkrét implementációtól, egy fuzzy irányítási rendszer működése jellemzően három fő lépésre bontható, ahogy azt a 4.1 ábra is szemlélteti [52]:

1. **Fuzzifikáció:** A rendszer éles, numerikus bemeneti adatait (pl. egy szenzortól érkező 28°C értéket) a rendszer átalakítja fuzzy értékekké. Ez azt jelenti, hogy minden releváns nyelvi értékhez (pl. *hideg, kellemes, meleg*) kiszámítja a bemeneti adat tagsági fokát.

2. **Szabálykiértékelés (Következtetés):** A rendszer a fuzzifikált bemenetek alapján kiértékeli a szabálybázis minden szabályát. Meghatározza, hogy az egyes szabályok antecedensei milyen mértékben teljesülnek (ezt nevezzük a szabály tüzelési erejének), majd ezen érték alapján levezeti az adott szabály konzekvensét.

3. **Defuzzifikáció:** A szabálykiértékelés eredményeként kapott aggregált fuzzy kimenetet a rendszer visszaalakítja egyetlen, éles (crisp) numerikus értékké, amely már közvetlenül felhasználható egy beavatkozó szerv (pl. egy motor vagy szelep) vezérlésére.

A szakirodalomban két domináns következtetési eljárás terjedt el, amelyek elsősorban a szabályok konzekvensének reprezentációjában és a defuzzifikáció módjában térnek el: a Mamdani- és a Takagi–Sugeno-típusú modellek.

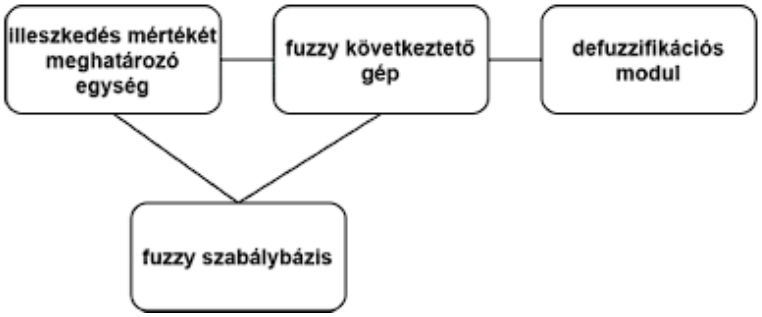

4.1. ábra. Egy fuzzy irányító rendszer általános blokkvázlata [32].

4.2.2. A Mamdani-típusú Következtetés

Az Ebrahim Mamdani által kifejlesztett, klasszikusnak számító megközelítés teljes mértékben a fuzzy halmazok világában dolgozik: mind a szabályok antecedense, mind a konzekvense fuzzy halmaz [50, 53]. A következtetés során a rendszer az egyes szabályok tüzelési ereje (ω_i) alapján módosítja (jellemzően "csonkolja") a szabályok konzekvens fuzzy halmazait, majd ezeket a módosított halmazokat egyetlen végső fuzzy halmazzá egyesíti (aggregálja), legtöbbször a maximum operátorral.

$$B^*(y) = \max_{i=1\ldots r} B_i^*(y) = \max_{i=1\ldots r} \min(\omega_i, B_i(y)) \tag{4.1}$$

Mivel a végeredmény egy fuzzy halmaz (egy "terület"), szükség van egy defuzzifikációs eljárásra, hogy éles kimeneti értéket kapjunk. A leggyakrabban használt módszer a súlypontszámítás (Center of Gravity, COG), amely megtalálja az aggregált fuzzy halmaz geometriai középpontját. A Mamdani-módszer nagy előnye az intuitív, könnyen értelmezhető, nyelvi alapú működés.

4.2.3. A Takagi–Sugeno-típusú Következtetés

A Takagi–Sugeno (TSK) modell egy hibrid megközelítést alkalmaz, amely hatékonyabbá teszi a számításokat [54, 55]. Az antecedens oldal itt is fuzzy halmazokon alapul, de a konzekvens nem egy fuzzy halmaz, hanem egy matematikai függvény:

$$R_i : \text{HA } x_1 \text{ az } A_{1,i} \text{ ÉS } \ldots, \text{ AKKOR } y_i = f_i(x_1, \ldots, x_n) \tag{4.2}$$

A leggyakoribb az ún. nulladrendű TSK modell, ahol f_i egy konstans érték ($y_i = c_i$). Ebben az esetben a rendszer kimenete az egyes szabályok kimeneteinek súlyozott átlaga, ahol a súlyokat a szabályok tüzelési ereje adja:

$$y = \frac{\sum_{i=1}^{r} \omega_i y_i}{\sum_{i=1}^{r} \omega_i} \tag{4.3}$$

Mivel a kimenet eleve egy éles érték, a TSK rendszerek nem igényelnek külön defuzzifikációs lépést, ami jelentősen csökkenti a számítási komplexitásukat. Ez teszi őket különösen alkalmassá beágyazott rendszerekben és adaptív modellekben való használatra.

4.2.4. A Klasszikus Módszerek Korlátai és Előnyei

A bemutatott klasszikus FIS modellek közös korlátja, hogy működésükhöz fedő, vagyis teljes szabálybázist igényelnek. Ez azt jelenti, hogy a bemeneti tér minden lehetséges pontjára kell, hogy létezzen legalább egy szabály, amely valamilyen mértékben illeszkedik. A bemeneti dimenziók számának növekedésével a szükséges szabályok száma exponenciálisan növekszik (ezt nevezik a "dimenziók átkának"), ami a szabálybázis kezelhetetlenségéhez és a számítási idő drasztikus növekedéséhez vezethet [52, 56].

Ezen korlátok ellenére a fuzzy rendszerek rendkívül hasznosak. Képesek kezelni a pontatlan, zajos szenzoradatokat és a rosszul definiált problémákat. Legnagyobb előnyük, hogy lehetővé teszik a szakértői tudás direkt integrálását a rendszerbe nyelvi szabályok formájában, így olyan feladatok is modellezhetők, amelyeknek nincs pontos matematikai leírása [52].

4.3. Fuzzy szabály interpoláció

Ahogy az előző fejezetben bemutatásra került, a klasszikus fuzzy következtető rendszerek (FIS) ereje a nyelvi szabályokon alapuló tudásreprezentációban rejlik. Ugyanakkor ezen rendszerek komoly gyakorlati korlátja a **teljes szabálylefedettség** (dense rule base) követelménye [51, 50]. Ez azt jelenti, hogy a bemeneti állapotteret a fuzzy szabályoknak "hézagmentesen" le kell fedniük, hogy bármilyen lehetséges bemeneti értékre a rendszer képes legyen érvényes kimenetet produkálni.

Kisebb, egy- vagy kétdimenziós problémáknál ez a feltétel még teljesíthető. Azonban komplex, többdimenziós rendszerek esetén (pl. egy robotkar több csuklójának vezérlése) a szükséges szabályok száma exponenciálisan növekszik a dimenziók számával. Ezt a jelenséget a "dimenziók átkának" (curse of dimensionality) fuzzy rendszerekre vonatkozó megfelelőjének is tekinthetjük. Egy ilyen *ritka* vagy *hézagos* (sparse) szabálybázis esetén a klasszikus következtetési eljárások csődöt mondanak, ha a bemeneti megfigyelés egy "szabálylyukba" esik, azaz nincs a közelében egyetlen aktív szabály sem. Ez valós idejű vezérlési alkalmazásokban elfogadhatatlan, mivel a rendszer képtelen reagálni [57, 58].

Ezen probléma feloldására jöttek létre a **fuzzy szabály-interpolációs (FRI)** módszerek, amelyek célja, hogy a meglévő, ritkásan elhelyezkedő szabályok közötti "logikai térben" is képesek legyenek becslést adni, lényegében interpolálva a legközelebbi szabályok között a várható következtetést. Ezzel drasztikusan csökkenthető a szükséges szabályok száma, mivel a tudásbázisnak elegendő csak a legfontosabb, legjellemzőbb pontokat tartalmaznia [58].

4.3.1. Az Interpolációs Módszerek Főbb Kategóriái

Az FRI eljárásokat alapvetően két nagy csoportra oszthatjuk aszerint, hogyan jutnak el a végső konklúzióig [59, 60, 61]:

- **Egylépéses módszerek:** Ezek az eljárások a kimenetet közvetlenül a bemeneti megfigyelés és az azt közrefogó szomszédos szabályok geometriai vagy logikai viszonyából, egyetlen lépésben számítják ki. A legkorábbi és legismertebb ilyen technika a **Kóczy-Hirota (KH) módszer**, amely a fuzzy halmazok α-vágatain (lényegében a tagsági függvények egy adott szint feletti "szeletein") alapuló lineáris távolságarányosságot alkalmazza [62]. A KH-módszer bár koncepcionálisan

egyszerű, hátránya, hogy a kapott interpolált konzekvens nem minden esetben lesz értelmes fuzzy halmaz (elveszítheti a konvexitását). Ezt a problémát orvosolták a későbbi, finomított egylépéses eljárások, mint a **Vass-Kalmár-Kóczy (VKK)** [63] vagy a **MACI** [64] módszerek.

- **Kétlépéses módszerek:** Ezek a technikák kifinomultabb logikát követnek. Az első lépésben a meglévő szabályokból interpolálnak egy teljesen új, virtuális szabályt, amelynek antecedense pontosan a megfigyelésre illeszkedik. A második lépésben pedig ezen az új szabályon hajtanak végre egy következtetést. Számos ilyen eljárás épül a **Baranyi-Kóczy-Gedeon-féle Általánosított Módszertanra (GM)** [65], amely referencia pontokon alapuló távolságmérést használ. Ide tartozik többek között a VEIN, LESFRI és FRIPOC eljáráscsalád [66, 67, 68].

4.3.2. A FIVE Módszer: Alkalmazás-orientált Interpoláció

Míg a korai FRI módszerek elsősorban elméleti jellegűek voltak, a valós idejű alkalmazások (pl. robotvezérlés) gyors és robusztus, éles (crisp) kimenetet produkáló eljárásokat igényeltek. Erre a gyakorlati igényre ad választ a **FIVE** (*Fuzzy rule Interpolation based on Vague Environment*) módszer, amelyet Kovács és Kóczy dolgozott ki [69, 70, 71].

A FIVE központi gondolata a fuzzy interpolációs probléma visszavezetése egy egyszerűbb, éles értékeken végzett interpolációra. Ezt a **bizonytalan környezet** (*Vague Environment*, VE) koncepciójának segítségével éri el [72]. A VE lényege, hogy a fuzzy partíciók alakját egy ún. **skálafüggvény** ($s(x)$) írja le, amely egyfajta lokális "metrikaként" vagy "rugalmas vonalzóként" funkcionál. Ahol a fuzzy halmazok sűrűn változnak (meredek a tagsági függvény), ott a skálafüggvény értéke nagy, "széthúzva" a teret, míg ahol a tagsági értékek alig változnak (lapos a függvény), ott "összenyomja" azt. A skálázott távolság két pont között így definiálható:

$$\delta_s(x_a, x_b) = \int_{x_b}^{x_a} s(x)\, dx \tag{4.4}$$

A 4.2 ábra szemlélteti ezt az átalakítást: a felső grafikon egy tipikus, különböző alakú fuzzy halmazokból álló partíciót mutat, míg az alsó grafikon az ebből levezetett skálafüggvényeket ábrázolja. Látható, hogy a meredekebb háromszög-élekhez magasabb skálafüggvény-értékek tartoznak. A 4.3 ábra pedig azt illusztrálja, hogy a keretrendszer hogyan képes összetettebb, például trapéz alakú tagsági függvényeket is kezelni két, megfelelő oldali meredekséggel rendelkező háromszög kombinációjaként.

A többdimenziós interpolációhoz a FIVE a Shepard-operátort [73] hívja segítségül. Ez a módszer egy inverz távolság-súlyozáson alapuló eljárás: a megfigyeléshez közelebbi szabálypontok nagyobb súllyal (befolyással) esnek latba a végső kimenet meghatározásakor. Singleton (egyértékű) konzekvensek esetén a kimenet a következőképpen számítható:

$$y(\mathbf{x}) = \begin{cases} c_k, & \text{ha } \mathbf{x} = \mathbf{a}_k \text{ valamely } k \text{ esetén,} \\ \dfrac{\sum_{k=1}^{r} \delta_{s,k}^{-\lambda} \cdot c_k}{\sum_{k=1}^{r} \delta_{s,k}^{-\lambda}}, & \text{egyébként,} \end{cases} \tag{4.5}$$

ahol $\mathbf{x}$ a többdimenziós megfigyelés, $\mathbf{a}_k$ a k-adik szabály antecedensének magja, c_k a konzekvense, $\delta_{s,k}$ a köztük lévő skálázott távolság, λ pedig egy, a súlyozás meredekségét befolyásoló pozitív kitevő.

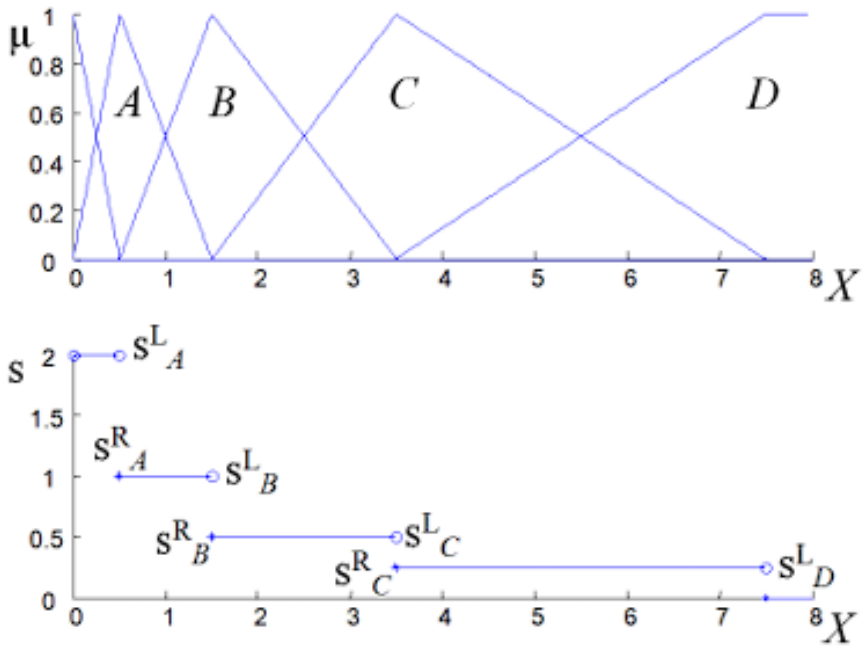

4.2. ábra. Fuzzy halmazok és a hozzájuk tartozó skálafüggvények [57].

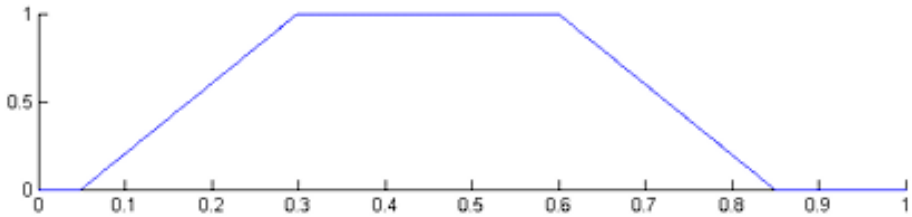

4.3. ábra. Trapéz alakú tagsági függvény, amely két háromszög alakú tagsági függvényből áll össze [61].

A FIVE módszer kiemelkedő számítási hatékonyságát az adja, hogy a skálafüggvények előre, a rendszer futása előtt meghatározhatók. Így a valós idejű következtetés során már csak a gyors távolságszámításra és a súlyozott átlagolásra van szükség, ami kiválóan alkalmassá teszi beágyazott és robotikai rendszerekben való alkalmazásra [71, 58]. A 4.4 ábra vizuálisan összegzi a módszer működését egy egyszerű, két szabályt tartalmazó rendszeren. Jól látható, hogy míg a klasszikus CRI módszer (CRI görbe) egy másfajta kimeneti felületet ad, addig a FIVE (Shepard görbék) egy sima, folytonos átmenetet képez a két szabály konzekvense között, hatékonyan kitöltve a "szabálylyukat". Az ábra azt is szemlélteti, hogy a λ paraméter változtatásával (pl. $\lambda = 1$ vs. $\lambda = 2$) hogyan befolyásolható az interpolációs görbe meredeksége.

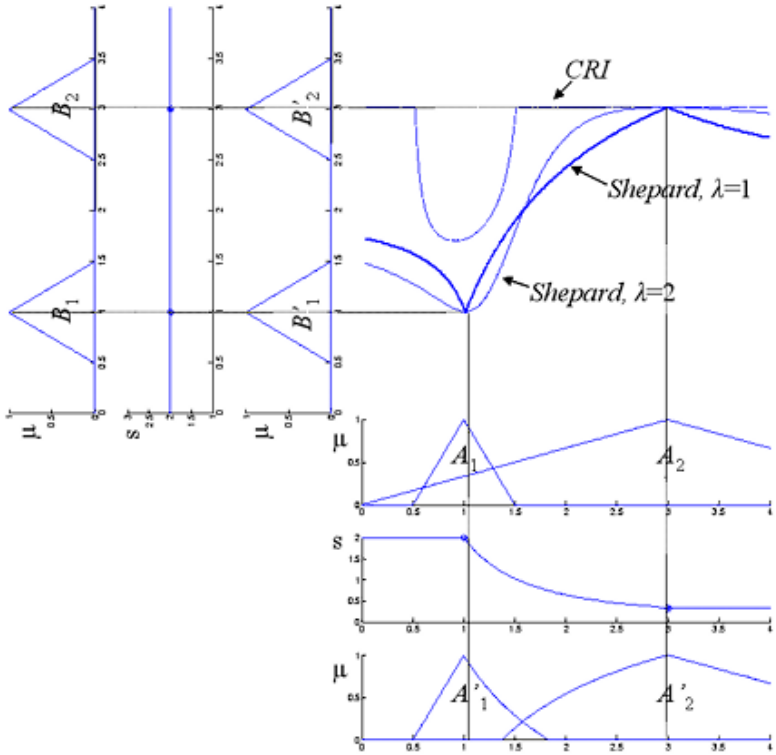

4.4. ábra. A FIVE módszer interpolációja két szabály esetén...

4.4. A Fuzzy Q-learning

A klasszikus Q-learning algoritmus, amely egy diszkrét Q-táblázatban tárolja az állapot-akció párok értékét, két komoly kihívással néz szembe a valós világbeli problémák során. Egyrészt a folytonos állapot- és akciótereket csak durva diszkretizáció árán képes kezelni, ami információveszteséghez és pontatlan vezérléshez vezethet. Másrészt, a Q-tábla mérete a dimenziók számával exponenciálisan nő, így már közepesen komplex feladatoknál is kezelhetetlenné válik.

Ezen korlátok leküzdésére a függvényapproximáció kínál megoldást. A **Fuzzy Q-learning (FQ-learning)** egy ilyen technika, amely a merev Q-táblázatot egy rugalmas fuzzy következtető rendszerrel (FIS) helyettesíti [74]. Ebben a keretrendszerben a Q-függvényt nem explicit módon tároljuk, hanem egy fuzzy szabálybázis segítségével approximáljuk, amely egy folytonos Q-felületet ír le az állapot-akció tér felett.

A FQ-learning lényege, hogy a rendszer a bemeneti állapot-akció párokat a fuzzy szabályrendszeren keresztül futtatva, valós időben számítja ki a hozzájuk tartozó Q-értéket. Ez a megközelítés több előnnyel is jár:

- **Folytonosság kezelése:** A fuzzy halmazok természetes módon kezelik a folytonos változókat, így nincs szükség mesterséges diszkretizációra.
- **Generalizáció:** A rendszer képes olyan állapot-akció párokra is becslést adni, amelyek nem esnek egybe egyetlen szabály magjával sem. A kimenet a közeli szabályok interpolált eredménye lesz, ami robusztusságot biztosít a zajjal szemben is [75].
- **Tudásintegráció:** A szabálybázis ember által olvasható formában tárolja a tudást, ami megkönnyíti a szakértői heurisztikák beépítését.

A FQ-learning rendszerekben leggyakrabban a számítási szempontból hatékony, nulladrendű Takagi–Sugeno (TSK) modellt alkalmazzák. A szabálybázisban a szabályok az állapot (S) és az akció (A) fuzzy halmazait képezik le egy éles, numerikus Q-értékre [76]:

$$\text{Ha } S \text{ az } S_i \text{ és } A \text{ az } A_u, \text{ akkor } \tilde{Q}(s,a) = Q_{i,u} \tag{4.6}$$

ahol $\tilde{Q}(s,a)$ a rendszer által becsült, közelítő Q-érték, $Q_{i,u}$ pedig az i-edik állapot és u-adik akció kombinációjához tartozó, tanult Q-érték. A végső, éles Q-érték az aktív szabályok konzekvenseinek súlyozott átlagaként áll elő.

Annak ellenére, hogy a FQ-learning megoldást kínál a folytonosság problémájára, a klasszikus fuzzy rendszerekhez hasonlóan továbbra is érzékeny a "dimenziók átkára". Egy nagy dimenziószámú probléma teljes lefedéséhez szükséges szabályok száma itt is exponenciálisan növekedhet. A modern kutatások ezt a kihívást különböző technikákkal, például adaptív szabálybázis-kezeléssel vagy a fuzzy rendszerek és a mély tanulás ötvözésével (deep fuzzy reinforcement learning) igyekeznek kezelni [77].

4.5. Fuzzy szabály-interpoláció alapú rendszerek

A Fuzzy Q-learning (FQ-learning) bevezetése fontos mérföldkő volt a megerősítéses tanulás területén, hiszen sikeresen oldotta fel a hagyományos Q-táblák korlátját a folytonos állapot- és akcióterek kezelésében. Azonban, ahogy a korábbi fejezetekben láthattuk, a klasszikus fuzzy következtető rendszerekre épülő FQ-learning módszerek örökölték azok Achilles-sarkát: a "dimenziók átkának" nevezett problémát. A rendszer alapját képező fuzzy szabálybázisnak a klasszikus esetben teljesen le kell fednie a bemeneti teret, ami a dimenziószám növekedésével a szükséges szabályok számának exponenciális növekedéséhez vezet [62]. Egy közepesen komplex, például 5 állapotváltozóval rendelkező rendszer esetén, ha minden változót csak 4 fuzzy halmazzal írunk le, a teljes lefedettséghez már $4^5 = 1024$ szabályra lenne szükség. Egy ilyen méretű szabálybázis létrehozása, tárolása és valós idejű kiértékelése a legtöbb gyakorlati alkalmazásban kivitelezhetetlen, ami súlyosan korlátozza a hagyományos FQ-learning skálázhatóságát.

Ezen skálázhatósági probléma feloldására a fuzzy szabály-interpolációs (FRI) módszerek kínálnak egy hatékony és elegáns paradigmaváltást. Ahelyett, hogy a teljes állapotteret sűrűn lefedő szabályrendszert követelnénk meg, az FRI eljárások lehetővé

teszik a **ritka, hézagos szabálybázisokon** (sparse rule base) való működést. Az alapelv az, hogy a tudásbázisnak elegendő csupán a legfontosabb "tudásszigeteket", azaz a rendszer viselkedése szempontjából kritikus szabálypontokat tartalmaznia. A szabályok által nem lefedett, ismeretlen területeken a rendszer nem mond csődöt, hanem a legközelebbi ismert szabálypontok között, intelligens becsléssel, vagyis **interpolációval** határozza meg a szükséges kimenetet [57, 61]. Ez a megközelítés drasztikusan csökkenti a rendszertervezéshez és a tanuláshoz szükséges szabályok számát, miközben a rendszer megőrzi általánosító képességét és robusztusságát.

Ez a hatékony, ritka tudásbázisokon alapuló következtetési paradigma nyitotta meg az utat a megerősítéses tanulás egy új generációja előtt. A koncepció legdirektebb alkalmazása a *FRIQ-learning* (Fuzzy Rule Interpolation-based Q-learning) módszer, amely a Fuzzy Q-learning keretrendszert egy fuzzy szabály-interpolációs motorral egészíti ki [32]. Ez a hibrid megközelítés célja, hogy egyesítse a Q-learning adaptív, tapasztalatalapú tanulási képességét az FRI rendszerek kompakt tudásreprezentációjával és generalizációs erejével. A következő alfejezetek részletesen bemutatják ennek az algoritmusnak a felépítését és működési mechanizmusát.

4.5.1. FRIQ-learning

A Fuzzy Rule Interpolation-based Q-learning (FRIQ-learning) algoritmus alaposabb elemzése, működési mechanizmusa, matematikai formalizálása, valamint a szabálybázis kezelésével kapcsolatos innovatív megoldások képezik a jelen fejezet tárgyát. Az algoritmus a „FIVE“fuzzy szabály-interpolációs módszeren alapuló megerősítéses tanulási technika [61, 59]. Ennek köszönhetően az FRIQ-learning folytonos állapot-, akció- és Q-érték dimenziókkal dolgozik, ami lehetővé teszi a hagyományos Q-learning diszkretizációból eredő korlátainak leküzdését.

A Q-függvény reprezentációja és a szabálybázis felépítése

A FRIQ-learning központi eleme a tudásbázis, amelyet egy ritka fuzzy szabályrendszer testesít meg. Ahelyett, hogy a Q-függvényt egy sűrű táblázatban tárolná, a modell az egyes fuzzy szabályokat a Q-függvény tartópontjaiként kezeli. A szabályok által nem lefedett területeken a Q-értékeket a rendszer a meglévő szabályok között, interpolációval becsli meg [61, 59]. Ez a tömör reprezentáció hatékonyabbá teszi a módszert, és lehetővé teszi az alkalmazását összetettebb feladatokban is [78, 79].

A rendszer működtető tudásbázisát (R szabálybázis) leíró i-edik ($i \in [1, m]$, ahol m a szabályok száma) r_i fuzzy szabály általános alakja a következő [61, 59]:

$$r_i : \textbf{Ha } s_1 \text{ az } S_{1i} \textbf{ És } s_2 \text{ az } S_{2i} \textbf{ És} \ldots \textbf{ És } s_n \text{ az } S_{ni} \textbf{ És } a \text{ az } A_i \textbf{ Akkor } Q(\mathbf{s}, a) = q_i$$

ahol $Q(\mathbf{s}, a)$ a közelítő Q-függvény, q_i pedig az i-edik szabály konzekvens értéke. Az S_{ji} ($j \in [1, n]$) az i-edik szabályhoz tartozó fuzzy halmaz a j-edik állapotdimenzió univerzumában, míg $\mathbf{s} \in \mathbf{S}$ az n dimenziós állapot megfigyelés az n dimenziós állapottérben, s_j pedig az $\mathbf{s}$ állapot j-edik ($j \in [1, n]$) komponense. Az A_i az i-edik szabály fuzzy halmaza az egydimenziós U akciótérben, ahol $a \in U$ a választott akció. A rendszer állapot–akció univerzuma így $(n + 1)$ dimenziós: n dimenzió az állapotokat, egy további dimenzió pedig az akcióteret reprezentálja. Az R szabálybázis összesen m darab $r_i \in R$ ($i \in [1, m]$) fuzzy szabályból áll.

A Q-függvény frissítése és interpolációja a FIVE modellel

A tanulási folyamat során a fuzzy szabályok q_i konzekvens értékei (Q-értékek) a temporális differencia módszer alapján kerülnek frissítésre. A „FIVE“ modellben a frissítés mértékét a szabály és az aktuális megfigyelés közötti távolság határozza meg: minél közelebb van egy szabály a megfigyeléshez, annál nagyobb súllyal módosul az értéke. Egy adott q_i konzekvens $(k+1)$-edik iterációban felvett új értékét az alábbi összefüggés adja meg [61, 59]:

$$q_i^{k+1} = \begin{cases} q_i^k + \Delta Q^{k+1}(\mathbf{s}, a) & \text{ha } (\mathbf{s}, a) = (\mathbf{s}_i, a_i) \text{ valamennyi } i\text{-re,} \\ q_i^k + \Delta Q^{k+1}(\mathbf{s}, a) \cdot \left(\frac{1/\delta_{v,i}^{\lambda}}{\sum_{j=1}^{m} 1/\delta_{v,j}^{\lambda}} \right) & \text{egyébként} \end{cases} \tag{4.7}$$

A képletben szereplő $\Delta Q^{k+1}(\mathbf{s}, a)$ a teljes Q-függvény frissítésének mértéke, amely a klasszikus Q-learning frissítési szabályát követi [61, 59]:

$$Q^{k+1}(\mathbf{s}, a) = Q^k(\mathbf{s}, a) + \Delta Q^{k+1}(\mathbf{s}, a) \tag{4.8}$$

$$\Delta Q^{k+1}(\mathbf{s}, a) = \alpha \cdot \left(g(\mathbf{s}, a, \mathbf{s}') + \gamma \cdot \max_{a' \in U} Q^k(\mathbf{s}', a') - Q^k(\mathbf{s}, a) \right) \tag{4.9}$$

ahol γ a diszkontfaktor, $\alpha \in [0, 1]$ a tanulási ráta, q_i^{k+1} az i-edik szabály singleton konzekvens értéke a $(k+1)$-edik iterációban, a a $\mathbf{s}$ állapotban végrehajtott akció, $\mathbf{s}'$ az újonnan megfigyelt állapot, $g(\mathbf{s}, a, \mathbf{s}')$ a jutalom az $\mathbf{s} \to \mathbf{s}'$ állapotátmenethez, Q^k a k-adik, míg Q^{k+1} a $(k+1)$-edik iterációban a „FIVE“ FRI modell által becsült konzekvens érték.

A $Q(\mathbf{s}, a)$ függvény a „FIVE“ FRI modell szerkezetébe helyettesítve az alábbi formában adható meg [61, 59]:

$$Q(\mathbf{s}, a) = \begin{cases} q_i & \text{ha } (\mathbf{s}, a) = (\mathbf{s}_i, a_i) \text{ valamennyi } i\text{-re,} \\ \sum_{i=1}^{m} \left(q_i \cdot \frac{(1/\delta_{v,i})^{\lambda}}{\sum_{j=1}^{m} (1/\delta_{v,j})^{\lambda}} \right) & \text{egyébként} \end{cases} \tag{4.10}$$

Ahol q_i az i-edik szabály konzekvens értéke ($i \in [1, m]$), $(\mathbf{s}, a)$ a megfigyelt, éles (crisp) állapot–akció páros, λ pedig a Shepard-paraméter, amelynek értéke jelen esetben megegyezik az antecedens dimenziók számával [80]. A m a szabálybázisban található szabályok darabszámát jelöli. A $\delta_{v,i}$ a skálázott, azaz súlyozott távolság az aktuális megfigyelés $(\mathbf{s}, a)$ és az i-edik szabály antecedense $(\mathbf{s}_i, a_i)$ között, amely a következőképpen definiálható [57]:

$$\delta_{v,i} = \delta_v((\mathbf{s}, a), (\mathbf{s}_i, a_i)) = \left[\sum_{j=1}^{n} \left(\int_{s_j^i}^{s_j} v_j(s_j) ds_j \right)^2 + \left(\int_{a_i}^{a} v(a) da \right)^2 \right]^{1/2} \tag{4.11}$$

Itt $(\mathbf{s}, a)$ jelöli az állapot–akció párost, $(\mathbf{s}_i, a_i)$ az i-edik szabály állapot–akció antecedensét, v_j az n dimenziós állapottér j-edik dimenziójának univerzumát ($j \in [1, n]$), s_j^i pedig az i-edik szabály j-edik állapotdimenzióját. Az a_i az i-edik szabály akció-univerzuma, míg $v_j(s_j)$ az adott állapotelemhez tartozó skálafüggvény, $v(a)$ pedig az akció-univerzumhoz rendelt skálafüggvény. A skálafüggvények meghatározzák az egyes fuzzy halmazok alakját és eloszlását [57].

Inkrementális szabálybázis építés és akcióválasztási stratégia

A FRIQ-learning tanulási folyamata nem egy teljesen üres szabálybázisból indul. Kezdetben a rendszer automatikusan előállít egy minimális, 2^{n+1} darab szabályt tartalmazó alapkészletet, ahol n az állapotdimenziók száma. Ezek az ún. sarokponti szabályok kijelölik az állapot–akció tér határait, és induláskor zérus konzekvens értékkel (Q-értékkel) rendelkeznek. A tanulási szakasz során a Vincze és Kovács által kidolgozott inkrementális építési mechanizmus [60] ezt a kezdeti szabálykészletet fokozatosan bővíti. Amikor a rendszer olyan régióba kerül, ahol a TD-hiba (δQ) számottevően nagy, és a közelben nincs releváns szabály, új szabály kerül a bázisba. Ha azonban a környezethez tartozó szabály már megtalálható, akkor csak annak Q-értékét frissíti a (4.7) összefüggés segítségével.

Az új szabály beillesztése az ágens környezetéből kapott megerősítő visszajelzés és a Q-függvény változása (ΔQ) alapján történik. Ha ΔQ meghalad egy előre rögzített küszöbértéket ($\Delta Q > \epsilon_Q$), és a legközelebbi szabály kellően távol helyezkedik el az adott ponttól, akkor a rendszer új szabályt ad hozzá a bázishoz. A potenciális szabályhelyek az állapot–akció tér rácshálós felosztásával adódnak, így új szabályok kizárólag a háló rögzített pontjaiban hozhatók létre ($s_{k+1} = s_k, \forall k > i, s_{i+1} = \frac{s_i + s_{i+2}}{2}$) [60]. Ha ΔQ nem éri el a küszöböt ($\Delta Q < \epsilon_Q$), nem történik szabálybeszúrás, hanem csupán a meglévő szabályok Q-értékeinek hangolása zajlik. Ez a folyamat minden iterációban ismétlődik mindaddig, amíg a tanulási szakasz be nem fejeződik. A végleges, működésre kész tudásbázis akkor áll elő, ha többé nem keletkeznek új szabályok, és a ΔQ értékei tartósan alacsonyak maradnak.

Az akcióválasztás során a rendszer vagy mohó, vagy ϵ-mohó stratégiát alkalmazhat. A mohó eljárás esetén a kiválasztott akció mindig az lesz, amely a legnagyobb Q-értéket ígéri az adott állapotban elérhető lehetőségek közül [61, 59].

$$a(\mathbf{s}) = \underset{a \in U}{\operatorname{argmax}}\ Q^{\pi}(\mathbf{s}, a) \tag{4.12}$$

Szabálybázis redukció az FRIQ-learningben

Az inkrementális építés eredményeként egy használható, de méretében nem feltétlenül optimális szabálybázis jön létre. A fölösleges szabályok, amelyek szerepét az interpoláció is betölthetné, vagy a túlzottan hasonló információt hordozó szabályok rontják a tudásbázis hatékonyságát. Ezeknek a redundáns elemeknek az eltávolítását és a szabálybázis tömörítését szolgálják a dekrementális redukciós stratégiák [81, 82]. A FRIQ-learning eredeti változata három, a tanulási folyamat után alkalmazható ilyen módszert tartalmaz [81, 82, 83].

A redukciós eljárások lényege, hogy a tanulási szakasz végére létrejött szabályhalmazt vizsgálják abból a szempontból, hogy egy szabály elengedhetetlen (kardinális) vagy elhagyható (redundáns). A folyamat célja, hogy a felesleges szabályok eltávolításával egy kisebb, de az eredetihez hasonló tudástartalommal rendelkező szabályrendszert hozzanak létre. A módszerek közös alapja, hogy a szabályok konzekvens részét, azaz a Q-értékeket veszik figyelembe. Az I.–III. redukciós módszerek dekrementális jellegűek: a teljes szabálybázisból indulnak ki, és abból törölnek szabályokat, lépésenként csökkentve a méretet.

Dekrementális redukciós stratégiák

Az I. stratégia [81, 82] azon az ötleten alapul, hogy a legkisebb abszolút Q-értékkel rendelkező szabályok jelentősége a legcsekélyebb. Az eljárás ezeket a szabályokat próbálja meg sorban eltávolítani: minden egyes szabály ideiglenes törlése után ellenőrzi

a rendszer teljesítményét. Ha a működés változatlan marad, a szabály végleg törlésre kerül.

A II. stratégia [81, 82] ezzel ellentétes megközelítést alkalmaz: a legnagyobb abszolút Q-értékű szabályokkal kezdi a vizsgálatot, feltételezve, hogy ezek között is előfordulhat redundancia.

A III. stratégia [81, 82] nem különálló szabályokat kezel, hanem csoportokat alakít ki a Q-értékek alapján. Első lépésként meghatározza a Q-értékek tartományát, majd ezt kettéosztva két szabályhalmazt hoz létre. A vizsgálat mindig a magasabb Q-értékű csoporttal indul: ha ennek felhasználásával a feladat továbbra is megoldható, a másik csoport véglegesen elvethető, és a folyamat a megmaradt szabályokkal folytatódik. Amennyiben ez nem vezet megfelelő működéshez, a törölt szabályokat visszahelyezi, majd a tartományt ismét megfelezi, és a csoportosítással újra próbálkozik.

Ez az ismétlődő felezési eljárás addig tart, amíg a tartomány annyira szűkké nem válik, hogy egy szabálycsoport egyértelműen eltávolítható. Ha a végső lépésben egy csoport csak egyetlen szabályt tartalmaz, és annak törlése a feladat megoldhatatlanságához vezet, akkor a szabály „állandó” státuszt kap, vagyis nem kerülhet többé eltávolításra.

Inkrementális redukciós stratégia

Az FRIQ-learning algoritmus fázisai

Az FRIQ-learning teljes folyamata két, jól elkülöníthető szakaszra osztható. Először az **inkrementális építési fázis** zajlik, amely során a rendszer a sarokponti szabályokból kiindulva, a tapasztalatokra építve fokozatosan bővíti és finomítja a tudásbázist [60]. Ezt követi az opcionális **dekrementális redukciós fázis**, amelynek feladata a már működőképes, de redundáns elemeket tartalmazó szabálybázis optimalizálása a felesleges szabályok kiszűrésével [81, 82].

5. fejezet

Többágensű Megerősítéses Tanulás (MARL)

A klasszikus megerősítéses tanulás (RL) keretrendszere jellemzően egyetlen ágens elszigetelt döntéshozatali folyamatát vizsgálja egy stacionárius környezetben. A valós világ problémáinak jelentős része az autonóm járművek flottakezelésétől kezdve a robotrajok koordinációján át a gazdasági rendszerek modellezéséig, azonban megköveteli, hogy egyszerre több, interakcióban lévő döntéshozó entitást vizsgáljunk. Ezt a paradigmát a többágensű megerősítéses tanulás (Multi-Agent Reinforcement Learning, MARL) írja le, amely a hagyományos RL és a játékelmélet metszetében helyezkedik el [84, 85].

5.1. Alapfogalmak és a nem-stacionaritás kihívása

Míg az egyágensű RL matematikai alapját a Markov-döntési folyamatok (MDP) adják, a többágensű rendszereket a **Markov-játékok** (Markov Games), más néven sztochasztikus játékok formalizálják [86]. Egy N ágensből álló Markov-játékot a $(S, A_1, \ldots, A_N, P, R_1, \ldots, R_N, \gamma)$ rendezett n-es írja le. Itt S a környezet globális állapota, A_i az i-edik ágens akciótere, P pedig az állapotátmeneti függvény, amely immár az összes ágens *együttes* akciójától ($\mathbf{a} = \{a_1, \ldots, a_N\}$) függ: $P(s'|s, \mathbf{a})$. Továbbá minden ágens rendelkezik egy saját jutalomfüggvénnyel, $R_i(s, \mathbf{a}, s')$-vel[86].

A MARL legkritikusabb elméleti kihívása a **nem-stacionaritás** (non-stationarity) problémája [87, 84]. Mivel az állapotátmeneteket és a jutalmakat a többi ágens cselekedetei is befolyásolják, egyetlen ágens szemszögéből a környezet dinamikája folyamatosan változik, ahogy a többi ágens is tanul és frissíti a politikáját. Matematikailag ez azt jelenti, hogy a $\mathbb{P}[S_{t+1}|S_t, A_{i,t}]$ valószínűség nem állandó az időben. Ez a jelenség érvényteleníti a klasszikus Q-learning és SARSA algoritmusok konvergencia-garanciáit, hiszen a Markov-tulajdonság az egyéni ágens szintjén sérül[84].

5.2. Kooperatív, kompetitív és vegyes környezetek

A MARL rendszerek az ágensek jutalomfüggvényeinek (R_i) viszonya alapján három fő kategóriába sorolhatók [84, 87]:

- **Teljesen kooperatív környezetek:** Az összes ágens pontosan ugyanazt a globális jutalmat kapja ($R_1 = R_2 = \cdots = R_N$). A cél a közös haszon maximalizálása. Jellemző példája a hálózatirányítás vagy egy mentőrobot-csapat [84, 88].

- **Teljesen kompetitív környezetek:** Jellemzően kétágensű, zéró összegű játékokat (zero-sum games) takar, ahol az egyik ágens nyeresége a másik ágens veszteségét jelenti ($R_1 = -R_2$). Ilyen környezetekben a cél gyakran a Nash-egyensúly elérése vagy a Minimax stratégia megtanulása [86].

- **Vegyes (általános összegű) környezetek:** Az ágenseknek saját, esetenként konfliktusban álló céljaik vannak, de bizonyos helyzetekben az együttműködés mindkettőjük számára kifizetődő lehet. Ezt a dinamikát modellezi például a fogolydilemma vagy a forgalomirányítás [89].

5.3. Kommunikáció, koordináció és a CTDE paradigma

A többágensű rendszerekben a globális S állapot ritkán figyelhető meg teljes egészében minden ágens számára. A gyakorlatban az ágensek csak lokális megfigyelésekkel (observations, O_i) rendelkeznek. Ezt a struktúrát a decentralizált részlegesen megfigyelhető Markov-döntési folyamatok (Dec-POMDP) írják le [90]. A lokális látótér megköveteli az ágensek közötti koordinációt, esetenként explicit kommunikációs csatornák (pl. üzenetküldés) kiépítését az együttműködéshez.

A nem-stacionaritás és a részleges megfigyelhetőség kezelésére a legszélesebb körben elfogadott modern megközelítés a **CTDE (Centralized Training with Decentralized Execution)** paradigma [89, 91]. Ennek lényege egy aszimmetrikus információfelhasználás:

1. **Centralizált tanítás:** A szimulációs tréning fázisában az algoritmus hozzáfér a környezet teljes, globális állapotához (S) és az összes ágens akciójához ($\mathbf{a}$). Ez lehetővé teszi a környezet stacionaritásának helyreállítását az értékfüggvények frissítésekor[89, 91].

2. **Decentralizált végrehajtás:** A valós alkalmazás (execution) során az ágensek politikái (π_i) már csak a saját, lokális megfigyeléseikre (o_i) támaszkodnak a döntéshozatalhoz, így nincs szükségük folyamatos, költséges globális adatkapcsolatra [89, 91].

5.4. Érték- és politika-reprezentáció: VDN, QMIX és COMA

A CTDE paradigma gyakorlati megvalósítása olyan architektúrákat eredményezett, amelyek a globális értékfüggvényeket (joint action-value functions) próbálják okosan felbontani (faktorizálni) az egyéni ágensek Q-értékeire. A legfontosabb mérföldkövek ezen a területen a [92, 91, 93]:

- **Value Decomposition Networks (VDN):** Ez a megközelítés azt feltételezi, hogy a globális együttes Q-érték (Q_{tot}) egyszerűen az egyéni ágensek lokális Q-értékeinek összege ($Q_{tot} = \sum Q_i$). Bár hatékony, ez az additív feltételezés erősen korlátozza a modell kifejezőerejét komplex interakciók esetén [92].

- **QMIX:** A VDN továbbfejlesztéseként a QMIX egy sokkal lazább, monotonitási feltételt szab meg: a globális Q_{tot} értéknek ugyanabban az irányban kell változnia, mint az egyéni Q_i értékeknek ($\frac{\partial Q_{tot}}{\partial Q_i} \geq 0$). Ezt egy keverő neurális hálózat (mixing network) segítségével éri el, amely a globális állapottérből nyeri a nemnegatív súlyokat, ezáltal sokkal komplexebb, nemlineáris koordinációt tesz lehetővé [91].
- **COMA (Counterfactual Multi-Agent Policy Gradients):** Az Actor-Critic módszerekre építve a COMA egy központi kritikust (Critic) használ, amely látja a teljes állapotot, és egy "kontrafaktuális" alapvonalat számít ki. Ez a mechanizmus képes pontosan meghatározni, hogy egy adott ágens konkrét akciója (szemben az általa választható összes többi akcióval) mekkora mértékben járult hozzá a globális jutalomhoz, megoldva ezzel a "hitel-hozzárendelés" (credit assignment) problémáját a kooperatív rendszerekben [93].

5.5. A MARL és az FRIQ-learning lehetséges kapcsolódási pontjai

Bár a bemutatott MARL architektúrák (QMIX, COMA) jellemzően mély neurális hálózatokra (Deep RL) épülnek, a többágensű környezetek egyik legfőbb korlátja továbbra is a dimenziók átka (curse of dimensionality). Az állapot- és akciótér mérete az ágensek számával exponenciálisan növekszik [84, 88].

Ebben a kontextusban a fuzzy szabály-interpolációra épülő FRIQ-learning (Fuzzy Rule Interpolation Q-learning) jelentős elméleti potenciált hordoz[61, 59]. A fuzzy rendszerek azon képessége, hogy a folytonos, hatalmas kiterjedésű állapottereket ritka (sparse) szabálybázisokkal is képesek lefedni, hatékony választ adhat a MARL skálázhatósági problémáira[62, 69, 82]. Továbbá a CTDE paradigmán belül az FRIQ-learning egyéni ágens-szinten történő alkalmazása lehetővé teheti, hogy a lokális megfigyelésekből (o_i) egy gyorsan tanuló, alacsony memóriaigényű és ember számára is interpretálható (XAI) szabályalapú politika szülessen, amely sokkal átláthatóbb, mint a neurális "fekete doboz" alapú decentralizált végrehajtók[82, 78, 47].

6. fejezet

Összefoglalás

Irodalomjegyzék

[1] George Firican. The history of Machine Learning. `https://www.lightsondata.com/the-history-of-machine-learning/`.

[2] Alexander L. Fradkov. Early History of Machine Learning. *IFAC PapersOnLine*, 2020.

[3] Frank Rosenblatt. The perceptron: A probabilistic model for information storage and organization in the brain. *Psychological Review*, 65(6):386–408, 1958.

[4] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E. Hinton. Imagenet classification with deep convolutional neural networks. In *Advances in Neural Information Processing Systems 25 (NIPS 2012)*, pages 1097–1105, 2012.

[5] Michael I. Jordan and Tom M. Mitchell. Machine learning: Trends, perspectives, and prospects. *Science*, 349(6245):255–260, 2015.

[6] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. Deep learning. *Nature*, 521(7553):436–444, 2015.

[7] Volodymyr et al. Mnih. Human-level control through deep reinforcement learning. *Nature*, 518(7540):529–533, 2015.

[8] Sebastian Thrun, Wolfram Burgard, and Dieter Fox. *Probabilistic Robotics*. MIT Press, 2005.

[9] Stuart Russell and Peter Norvig. *Mesterséges intelligencia modern megközelítésben*. Panem Kiadó, Budapest, 2 edition, 2005.

[10] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.

[11] Trevor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning*. Springer, 2nd edition, 2009.

[12] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.

[13] Corinna Cortes and Vladimir Vapnik. Support-vector networks. *Machine Learning*, 20(3):273–297, 1995.

[14] Andre Esteva, Brett Kuprel, Roberto A Novoa, Justin Ko, Susan M Swetter, Helen M Blau, and Sebastian Thrun. Dermatologist-level classification of skin cancer with deep neural networks. *Nature*, 542(7639):115–118, 2017.

[15] Joy Buolamwini and Timnit Gebru. Gender shades: Intersectional phenotypic biases in commercial gender classification. In *Proceedings of the 1st Conference on Fairness, Accountability and Transparency*, volume 81 of *Proceedings of Machine Learning Research*, pages 77–91. PMLR, 2018.

[16] Anil K Jain, M Narasimha Murty, and Patrick J Flynn. Data clustering: a review. *ACM Computing Surveys (CSUR)*, 31(3):264–323, 1999.

[17] Martin Ester, Hans-Peter Kriegel, Jörg Sander, and Xiaowei Xu. A density-based algorithm for discovering clusters in large spatial databases with noise. In *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining (KDD'96)*, pages 226–231. AAAI Press, 1996.

[18] Laurens van der Maaten and Geoffrey Hinton. Visualizing data using t-sne. *Journal of Machine Learning Research*, 9(Nov):2579–2605, 2008.

[19] Ian T Jolliffe. *Principal Component Analysis*. Springer, 2 edition, 2002.

[20] Geoffrey E Hinton and Ruslan R Salakhutdinov. Reducing the dimensionality of data with neural networks. *Science*, 313(5786):504–507, 2006.

[21] Rakesh Agrawal and Ramakrishnan Srikant. Fast algorithms for mining association rules in large databases. In *Proceedings of the 20th International Conference on Very Large Data Bases (VLDB)*, pages 487–499. Morgan Kaufmann, 1994.

[22] Rob Kitchin. *The Data Revolution: Big Data, Open Data, Data Infrastructures and Their Consequences*. Sage Publications, 2014.

[23] Ian J. Goodfellow, Jonathon Shlens, and Christian Szegedy. Explaining and harnessing adversarial examples. *arXiv preprint*, arXiv:1412.6572, 2014.

[24] Amal Adadi and Mohammed Berrada. Peeking inside the black-box: A survey on explainable artificial intelligence (xai). *IEEE Access*, 6:52138–52160, 2018.

[25] Lotfi A Zadeh. Fuzzy sets. *Information and Control*, 8(3):338–353, 1965.

[26] Sinno Jialin Pan and Qiang Yang. A survey on transfer learning. *IEEE Transactions on Knowledge and Data Engineering*, 22(10):1345–1359, 2009.

[27] Chelsea Finn, Pieter Abbeel, and Sergey Levine. Model-agnostic meta-learning for fast adaptation of deep networks. In *Proceedings of the 34th International Conference on Machine Learning (ICML)*, pages 1126–1135, 2017.

[28] Josh Tobin, Rachel Fong, Alex Ray, Jonas Schneider, Wojciech Zaremba, and Pieter Abbeel. Domain randomization for transferring deep neural networks from simulation to the real world. In *2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 23–30. IEEE, 2017.

[29] Olivier Chapelle, Bernhard Schölkopf, and Alexander Zien. *Semi-Supervised Learning*. MIT Press, 2006.

[30] Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. A simple framework for contrastive learning of visual representations. *Proceedings of the 37th International Conference on Machine Learning (ICML)*, pages 1597–1607, 2020.

[31] Richard S Sutton and Andrew G Barto. *Reinforcement Learning: An Introduction.* A Bradford Book, 2 edition, 2018.

[32] Tompa Tamás. *Fuzzy szabály-interpolációs állapotgép modellek és hangolási eljárásaik.* Ph.d. értekezés, Miskolci Egyetem, Gépészmérnöki és Informatikai Kar, Miskolc, 2023.

[33] Martin L Puterman. *Markov Decision Processes: Discrete Stochastic Dynamic Programming.* John Wiley & Sons, 1994.

[34] Richard Bellman. *Dynamic Programming.* Princeton University Press, 1957.

[35] Leslie Pack Kaelbling, Michael L. Littman, and Andrew W. Moore. Reinforcement learning: A survey. *Journal of Artificial Intelligence Research*, 4:237–285, 1996.

[36] Dimitri P. Bertsekas and John N. Tsitsiklis. *Neuro-Dynamic Programming.* Athena Scientific, 1996.

[37] Christopher John Cornish Hellaby Watkins. *Learning from Delayed Rewards.* PhD thesis, King's College, Cambridge, 1989.

[38] Gavin A Rummery and Mahesan Niranjan. On-line q-learning using connectionist systems. Technical Report CUED/F-INFENG/TR 166, Cambridge University Engineering Department, 1994.

[39] Peter Auer, Nicolò Cesa-Bianchi, and Paul Fischer. Finite-time analysis of the multiarmed bandit problem. *Machine Learning*, 47(2-3):235–256, 2002.

[40] William R Thompson. On the likelihood that one unknown probability exceeds another in view of some sample evidence. *Biometrika*, 25(3/4):285–294, 1933.

[41] Andrew Y Ng, Daishi Harada, and Stuart Russell. Policy invariance under reward transformations: Theory and application to reward shaping. In *International Conference on Machine Learning*, pages 278–287, 1999.

[42] Tom Schaul, John Quan, Ioannis Antonoglou, and David Silver. Prioritized experience replay. In *International Conference on Learning Representations*, 2015.

[43] Yoshua Bengio and Yves Grandvalet. No unbiased estimator of the variance of the cross-validation estimator. *Journal of Machine Learning Research*, 5:1089–1105, 2004.

[44] Andrea Bonarini. Reinforcement learning and fuzzy logic: A survey. In *Fuzzy logic and Soft Computing: Proceedings of the 5th International Fuzzy Systems Association World Congress*, pages 159–165. Springer, 1996.

[45] Rui Li and Xinggang J Zeng. Fuzzy reinforcement learning: A survey. *IEEE Transactions on Fuzzy Systems*, 25(6):1361–1372, 2017.

[46] Hans-Jürgen Zimmermann. *Fuzzy set theory—and its applications.* Springer Science & Business Media, 1991.

[47] Timothy J Ross. *Fuzzy logic with engineering applications.* John Wiley & Sons, 2010.

[48] Ronald R Yager. A class of fuzzy measures. *Fuzzy Sets and Systems*, 4(1):93–102, 1980.

[49] József Dombi. A general class of fuzzy operators, the de morgan class of fuzzy operators and fuzziness measures induced by fuzzy operators. *Fuzzy Sets and Systems*, 8(2):149–163, 1982.

[50] E. H. Mamdani. An experiment in linguistic synthesis with a fuzzy logic controller. In *International Journal of Man-Machine Studies*, volume 7, pages 1–13, 1975.

[51] Lotfi A. Zadeh. Outline of a new approach to the analysis of complex systems and decision processes. *IEEE Transactions on Systems, Man, and Cybernetics*, 3(1):28–44, 1973.

[52] László T. Kóczy and Domonkos Tikk. *Fuzzy rendszerek.* TypoTEX, Budapest, 2000.

[53] B. R. Larsen. Fuzzy logic and its applications in control systems. *Automatica*, 11:103–112, 1975.

[54] T. Takagi and M. Sugeno. Fuzzy identification of systems and its applications to modeling and control. *IEEE Transactions on Systems, Man, and Cybernetics*, 15(1):116–132, 1985.

[55] M. Sugeno. Industrial production systems and fuzzy control. *IFSA-88*, pages 1–9, 1985.

[56] P. Horváth and L. Szabó. Complexity analysis of fuzzy rule bases. *International Journal of Fuzzy Systems*, 22(4):678–690, 2020.

[57] Kovács Sz. Extending the fuzzy rule interpolation 'five' by fuzzy observation. In Bernd Reusch, editor, *Advances in Soft Computing: Computational Intelligence – Theory and Applications*, pages 485–497. Springer, Germany, 2006.

[58] Szilveszter Kovács. Fuzzy rule interpolation in practice. In *Proceedings of SCIS & ISIS 2006*. Japan Society for Fuzzy Theory and Intelligent Informatics, 2006.

[59] Dávid Vincze and Szilveszter Kovács. Fuzzy rule interpolation-based q-learningg, proceedings of the 10th international symposium of hungarian researchers on computational intelligence and informatics. In *2009 5th International Symposium on Applied Computational Intelligence and Informatics (SACI)*. IEEE, 2009.

[60] Dávid Vincze and Szilveszter Kovács. Incremental rule base creation with fuzzy rule interpolation based q-learning. In Imre J. Rudas et al., editors, *Computational Intelligence in Engineering*, volume 313 of *Studies in Computational Intelligence*, pages 191–203. Springer-Verlag, Berlin Heidelberg, 2010.

[61] Dávid Vincze. *Fuzzy Rule Interpolation-based Q-learning.* Phd dissertation, University of Miskolc, Faculty of Mechanical Engineering and Informatics, Miskolc, Hungary, 2013.

[62] L. T. Kóczy and K. Hirota. Size reduction by interpolation in fuzzy rule bases. *IEEE Transactions on Systems, Man, and Cybernetics - Part B: Cybernetics*, 27:14–25, 1997.

[63] G. Vass, L. Kalmár, and L. T. Kóczy. Extension of the fuzzy rule interpolation method. In *Proceedings of the International Conference on Fuzzy Sets Theory and Applications (FSTA '92)*, pages 1–6, Liptovský Mikuláš, Czechoslovakia, 1992.

[64] D. Tikk and P. Baranyi. Comprehensive analysis of a new fuzzy rule interpolation method. *IEEE Transactions on Fuzzy Systems*, 8(3):281–296, 2000.

[65] P. Baranyi, L. T. Kóczy, and T. D. Gedeon. A generalized concept for fuzzy rule interpolation. *IEEE Transactions on Fuzzy Systems*, 12(6):820–837, 2004.

[66] Zs. Cs. Johanyák and Sz. Kovács. Vague environment-based two-step fuzzy rule interpolation method. In *Proceedings of the 5th Slovakian-Hungarian Joint Symposium on Applied Machine Intelligence and Informatics (SAMI 2007)*, pages 189–200, Poprad, Slovakia, 2007.

[67] Zs. Cs. Johanyák and Sz. Kovács. Fuzzy rule interpolation by the least squares method. In *Proceedings of the 7th International Symposium of Hungarian Researchers on Computational Intelligence (HUCI 2006)*, pages 495–506, Budapest, Hungary, 2006.

[68] Zs. Cs. Johanyák and Sz. Kovács. Fuzzy rule interpolation based on polar cuts. In B. Reusch, editor, *Computational Intelligence, Theory and Applications*, pages 499–511. Springer Berlin Heidelberg, Berlin, Germany, 2006.

[69] Szilveszter Kovács and László T. Kóczy. Approximate fuzzy reasoning based on interpolation in the vague environment of the fuzzy rule base as a practical alternative of the classical cri. In *Proceedings of the 7th International Fuzzy Systems Association World Congress*, pages 144–149, Prague, Czech Republic, 1997.

[70] Szilveszter Kovács and László T. Kóczy. The use of the concept of vague environment in approximate fuzzy reasoning. *Tatra Mountains Mathematical Publications*, 12:169–181, 1997.

[71] Szilveszter Kovács. New aspects of interpolative reasoning. In *Proceedings of the 6th International Conference on Information Processing and Management of Uncertainty in Knowledge-Based Systems (IPMU)*, pages 477–482, Granada, Spain, 1996.

[72] Frank Klawonn and Rudolf Kruse. A method for interpolation in fuzzy rule-based systems based on vague environment. *Fuzzy Sets and Systems*, 146(1):1–22, 2004.

[73] Donald Shepard. A two-dimensional interpolation function for irregularly-spaced data. *Proceedings of the 1968 ACM National Conference*, pages 517–524, 1968.

[74] Patrick-Yves Glorennec. Fuzzy q-learning and dynamical fuzzy q-learning. *International Journal of Approximate Reasoning*, 17(4):439–460, 1997.

[75] Chuen-Tsai Sun and Chi-Heng Lee. Fuzzy adaptive learning control network based on q-learning (falcon-q). *IEEE Transactions on Systems, Man, and Cybernetics*, 31(1):32–41, 2001.

[76] Andrea Bonarini. Delayed reinforcement, fuzzy q-learning and fuzzy logic controllers. In Francisco Herrera and José Luis Verdegay, editors, *Genetic Algorithms and Soft Computing*, volume 8 of *Studies in Fuzziness*, pages 447–466. Physica-Verlag, Berlin, Germany, 1996.

[77] Chih-Yang Lin, Tzung-Pei Hong, and Li-Wei Ko. Deep fuzzy reinforcement learning for control systems. *IEEE Access*, 6:38600–38613, 2018.

[78] Tamás Tompa and Szilveszter Kovács. Q-learning vs. friq-learning in the maze problem. In *2015 6th IEEE International Conference on Cognitive Infocommunications (CogInfoCom)*. IEEE, 2015.

[79] Tamás Tompa, Dávid Vincze, and Szilveszter Kovács. The pong game implementation with the friq-learning reinforcement learning algorithm. In *Proceedings of the 2015 16th International Carpathian Control Conference (ICCC)*. IEEE, 2015.

[80] D. Tikk, I. Joó, L. Kóczy, P. Várlaki, B. Moser, and T. D. Gedeon. Stability of interpolative fuzzy kh controllers. *Fuzzy Sets and Systems*, 125(1):105–119, 2002.

[81] Dávid Vincze and Szilveszter Kovács. Reduced rule base in fuzzy rule interpolation-based q-learning. In *Proceedings of the 10th International Symposium of Hungarian Researchers on Computational Intelligence and Informatics (CINTI)*, pages 533–544, Budapest, Hungary, 2009. Budapest Tech.

[82] Dávid Vincze and Szilveszter Kovács. Rule-base reduction in fuzzy rule interpolation-based q learning. *Recent Innovations in Mechatronics (RIiM)*, 2(1-2), 2015.

[83] Tamás Tompa and Szilveszter Kovács. Clustering-based fuzzy knowledgebase reduction in the friq-learning. In *2017 IEEE 15th International Symposium on Applied Machine Intelligence and Informatics (SAMI)*. IEEE, 2017.

[84] Lucian Busoniu, Robert Babuska, and Bart De Schutter. A comprehensive survey of multiagent reinforcement learning. *IEEE Transactions on Systems, Man, and Cybernetics, Part C (Applications and Reviews)*, 38(2):156–172, 2008.

[85] Lucian Buşoniu, Robert Babuška, and Bart De Schutter. Multi-agent reinforcement learning: An overview. In Danny Weyns and Samira Ossowski, editors, *Innovations in Multi-Agent Systems and Applications I*, volume 310 of *Studies in Computational Intelligence*, pages 183–221. Springer, Berlin, Heidelberg, 2010.

[86] Michael L Littman. Markov games as a framework for multi-agent reinforcement learning. In *Machine learning proceedings 1994*, pages 157–163. Elsevier, 1994.

[87] Pablo Hernandez-Leal, Bilal Kartal, and Matthew E Taylor. A survey and critique of multiagent deep reinforcement learning. *Autonomous Agents and Multi-Agent Systems*, 33(6):750–797, 2019.

[88] Sven Gronauer and Klaus Diepold. Multi-agent deep reinforcement learning: a survey. *Artificial Intelligence Review*, 55(2):895–943, 2022.

[89] Ryan Lowe, Yi I Wu, Aviv Tamar, Jean Harb, OpenAI Pieter Abbeel, and Igor Mordatch. Multi-agent actor-critic for mixed cooperative-competitive environments. *Advances in neural information processing systems*, 30, 2017.

[90] Frans A Oliehoek and Christopher Amato. *A concise introduction to decentralized POMDPs*. Springer, 2016.

[91] Tabish Rashid, Mikayel Samvelyan, Christian Schroeder, Gregory Farquhar, Jakob Foerster, and Shimon Whiteson. Qmix: Monotonic value function factorisation for deep multi-agent reinforcement learning. In *International conference on machine learning*, pages 4295–4304. PMLR, 2018.

[92] Peter Sunehag, Guy Lever, Audrunas Gruslys, Wojciech Marian Czarnecki, Vinicius Zambaldi, Max Jaderberg, Marc Lanctot, Nicolas Sonnerat, Joel Z Leibo, Karl Tuyls, et al. Value-decomposition networks for cooperative multi-agent learning. In *Proceedings of the 17th International Conference on Autonomous Agents and MultiAgent Systems*, pages 2085–2087, 2018.

[93] Jakob Foerster, Gregory Farquhar, Triantafyllos Afouras, Nantas Nardelli, and Shimon Whiteson. Counterfactual multi-agent policy gradients. In *Proceedings of the AAAI conference on artificial intelligence*, volume 32, 2018.

CD Használati útmutató